Аналитический документ: Логика AI-оператора

Дата: 2026-04-08 (rev. 1.2) **Автор:** Курганский Антон

0. Краткое резюме

Проблема исходного описания: ТЗ содержит внутренние противоречия — система одновременно "передаёт диалог оператору" и "продолжает отвечать AI", нет порога уверенности, таймаутов и механизма защиты от гонки состояний. В текущем виде реализация неизбежно приведёт к дублированию ответов, галлюцинациям AI и деградации клиентского опыта.

Ключевое решение: AI-оператор — первая линия обработки входящих сообщений. Он классифицирует обращение, генерирует ответ при достаточной уверенности и блокируется (взаимоисключение на уровне диалога) при подключении живого оператора. Оператор видит полный контекст работы AI.

Что входит в MVP:

- Классификатор тем (чувствительная / нечувствительная)
- Генерация ответа по базе знаний с порогом уверенности
- Дебаунсинг, таймауты, заглушка, автоэскалация
- Блокировка AI при подключении оператора (взаимоисключение)
- Кнопка "Позвать оператора" для клиента
- Отображение ответа AI + источника в интерфейсе оператора

Топ-5 открытых вопросов к PM:

1. Какой порог уверенности считается достаточным и кто его пересматривает?
2. Кто ведёт и обновляет список чувствительных тем?
3. Какие конкретные значения таймаутов (заглушка / максимум)?
4. Что означает "оператор взял диалог" — открыл вкладку, нажал "Принять" или отправил сообщение?
5. Что происходит при эскалации в нерабочее время — автоответ или только AI без эскалации?

1. Проблема и контекст

ЧТО РЕШАЕТ ФУНКЦИЯ

AI-оператор — автоматический агент, отвечающий клиентам вместо живого оператора. Цель: снизить нагрузку на поддержку, ускорить время ответа, обрабатывать типовые обращения без участия человека.

ПОЧЕМУ НЕЛЬЗЯ ОТДАВАТЬ В РАЗРАБОТКУ В ТЕКУЩЕМ ВИДЕ

1. **Конфликт управления диалогом** (п. 4 vs п. 5): система одновременно "передаёт диалог оператору" и "продолжает отвечать AI".
2. **Нет порога уверенности** (п. 3 и 6): AI будет галлюцинировать на чувствительных темах.
3. **Нет таймаута на генерацию** (п. 8): "клиент просто ждёт" противоречит требованию "не должен долго оставаться без ответа".
4. **Нет механизма недовольства** (п. 9): неясно, что триггерит подключение оператора.
5. **Оператор слеп к логике рассуждений AI** (п. 10): риск продолжить некачественный ответ.
6. **Проблема синхронизации** (п. 7): ответы на каждое сообщение по отдельности приведут к дублированию.

2. Требования к системе

2.1 ФУНКЦИОНАЛЬНЫЕ ТРЕБОВАНИЯ

FR-01

`[MUST MVP]`

Система определяет**тип обращения** до генерации ответа (чувствительная тема / типовой вопрос / нераспознанный).

FR-02

`[MUST MVP]`

AI генерирует ответ только если обращение**не относится к чувствительным темам**.

FR-03

`[MUST MVP]`

AI отправляет ответ клиенту только если**уверенность модели ≥ CONFIDENCE_THRESHOLD**. Конкретное значение порога — `[ГИПОТЕЗА]`, согласуется с PM и ML-командой после анализа распределения скоров.

FR-04

`[MUST MVP]`

Если уверенность < порога —**диалог передаётся оператору** с черновиком ответа AI и причиной.

FR-05

`[MUST MVP]`

Если тема чувствительная —**AI не отвечает**, диалог немедленно уходит оператору с пометкой темы.

FR-06

`[MUST MVP]`

Как только**оператор взял диалог** — AI **прекращает генерацию** по этому диалогу.

FR-07

`[MUST MVP]`

При нескольких сообщениях подряд с паузой < DEBOUNCE_TIMEOUT — AI**ждёт паузы** и отвечает на агрегированный контекст.

FR-08

`[MUST MVP]`

Если генерация > TYPING_INDICATOR_TIMEOUT — клиенту отправляется**заглушка**: "Мы уже изучаем ваш вопрос, ответим через несколько секунд".

FR-09

`[MUST MVP]`

Если генерация > MAX_GENERATION_TIMEOUT — диалог**автоматически передаётся оператору**.

FR-10

`[MUST MVP]`

Клиент может**явно запросить оператора** (кнопка или фраза-триггер) — AI останавливается, диалог уходит оператору.

FR-11

`[MUST MVP]`

Оператор видит**ответ AI + источник из базы знаний / причину передачи**.

FR-12

`[MUST MVP]`

Оператор**не дублирует ответ AI**: видит историю и продолжает диалог с учётом уже сказанного.

FR-13

`[MUST MVP]`

При событии "оператор взял диалог" —**отменить незавершенную генерацию**, запретить отправку уже сформированного буфера. Диалог блокируется для AI (взаимоисключение на уровне диалога).

FR-14

`[MUST MVP]`

При эскалации в нерабочее время (нет операторов в линии) — клиент получает**автоответ** с временем следующего ответа; диалог сохраняется в очереди. *(Конкретная формулировка — `[ГИПОТЕЗА]`, согласуется с PM.)*

2.2 НЕФУНКЦИОНАЛЬНЫЕ ТРЕБОВАНИЯ

NFR-01

`[MUST MVP]`

Время ответа AI — не более**10 сек** в 95% случаев (P95).

NFR-02

`[MUST MVP]`

Конкурентная обработка диалогов без взаимного влияния (изолированные очереди).

NFR-03

`[MUST MVP]`

Все действия AI логируются с меткой времени, ID диалога и причиной.

NFR-04

`[ГИПОТЕЗА]`

Архитектура позволяет подключить CRM в v2 без переписывания ядра.

> **Явная граница MVP:** AI работает только с базой знаний. Персональные данные клиента из CRM недоступны (реализация в v2).

3. Целевая логика работы

3.1 ТЕКСТОВОЕ ОПИСАНИЕ

1. Клиент отправляет сообщение.
2. Система ожидает паузу DEBOUNCE_TIMEOUT — если клиент продолжает набирать, ждёт окончания.
3. Классификация обращения:
   - **Чувствительная тема** → немедленно оператору с пометкой; AI не отвечает.
   - **Обычный вопрос** → AI начинает генерацию.
4. Если генерация > TYPING_INDICATOR_TIMEOUT → клиенту отправляется заглушка.
5. Если генерация > MAX_GENERATION_TIMEOUT → оператору; AI останавливается.
6. Оценка уверенности:
   - **≥ порога** → ответ клиенту; оператор видит ответ + источник.

- ‹ **порога** → оператору с черновиком.

7. Если **оператор взял диалог** — немедленное взаимоисключение: незавершенная генерация отменяется, AI блокируется.
8. Клиент может в любой момент нажать "Позвать оператора" → AI останавливается.
9. При эскалации без операторов в линии → автоответ клиенту, диалог в очередь.

3.2 КОМПАКТНАЯ СХЕМА СОСТОЯНИЙ (MERMAID)

Подробная визуальная схема потока приведена в **Приложении Б**.

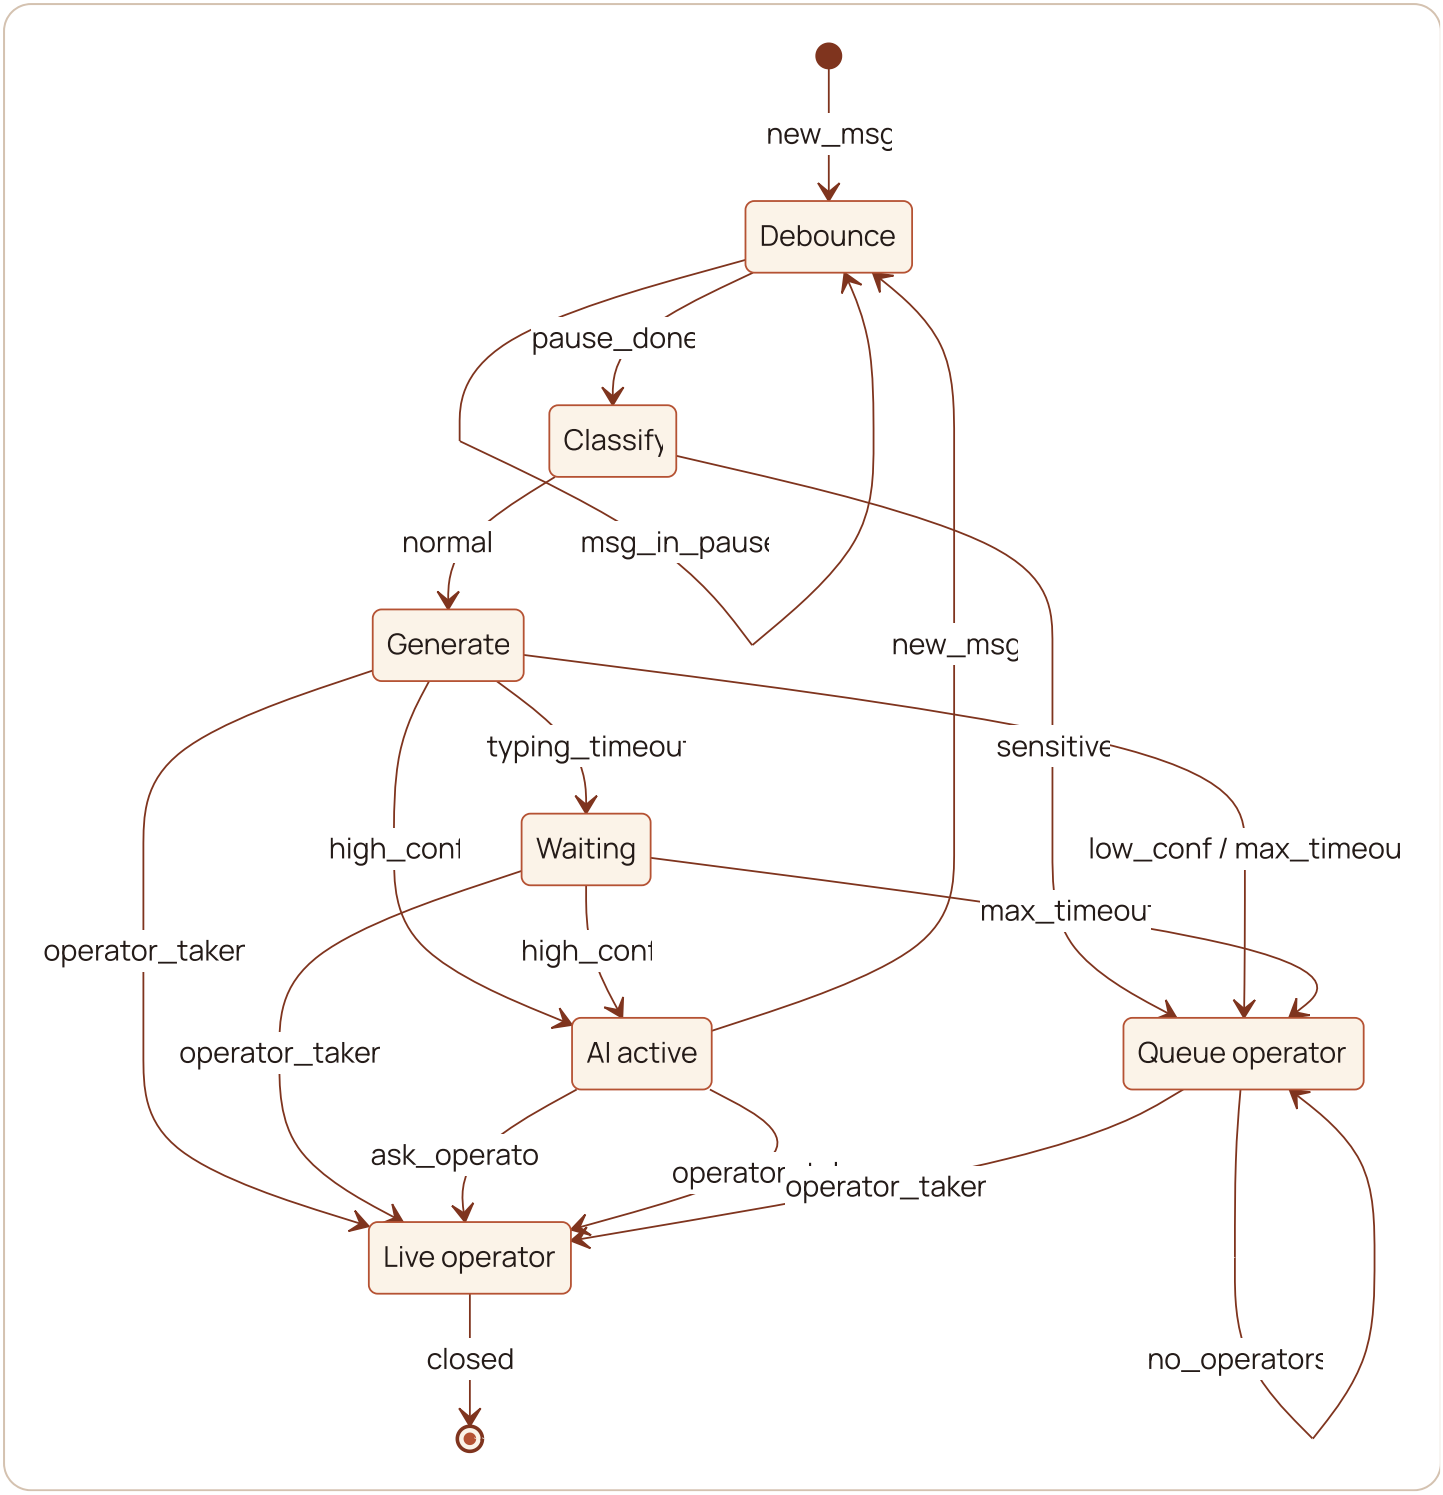

3.3 ТАБЛИЦА СОСТОЯНИЙ И ДОПУСТИМЫХ ПЕРЕХОДОВ

`[*] / AI_ACTIVE`	
`DEBOUNCING`	
получено сообщение клиента	

`DEBOUNCING`	`DEBOUNCING`
новое сообщение в пределах DEBOUNCE_TIMEOUT	
`DEBOUNCING`	`CLASSIFYING`
пауза ≥ DEBOUNCE_TIMEOUT	
`CLASSIFYING`	`OPERATOR_PENDING`
тема = чувствительная	
`CLASSIFYING`	`AI_GENERATING`
тема = обычная / нераспознанная	
`AI_GENERATING`	`AI_WAITING`
генерация > TYPING_INDICATOR_TIMEOUT	
`AI_GENERATING`	`OPERATOR_PENDING`
генерация > MAX_GENERATION_TIMEOUT ИЛИ уверенность < порога	
`AI_GENERATING`	`AI_ACTIVE`
уверенность ≥ порога, ответ отправлен	
`AI_GENERATING`	`OPERATOR_ACTIVE`
оператор взял диалог (взаимоисключение → генерация отменена)	
`AI_WAITING`	`OPERATOR_PENDING`
генерация > MAX_GENERATION_TIMEOUT	
`AI_WAITING`	`AI_ACTIVE`
уверенность ≥ порога, ответ отправлен	
`AI_WAITING`	`OPERATOR_ACTIVE`
оператор взял диалог (взаимоисключение → генерация отменена)	
`AI_ACTIVE`	`DEBOUNCING`
новое сообщение клиента	

`AI_ACTIVE`	`OPERATOR_ACTIVE`	клиент нажал "Позвать оператора" ИЛИ оператор взял диалог
`OPERATOR_PENDING`	`OPERATOR_ACTIVE`	оператор взял диалог
`OPERATOR_PENDING`	`OPERATOR_PENDING`	нет операторов → автоответ клиенту
`OPERATOR_ACTIVE`	`[*]`	оператор закрыл диалог

3.4 ЧТО AI ОБРАБАТЫВАЕТ / НЕ ОБРАБАТЫВАЕТ

FAQ, типовые вопросы по продукту	Да	При уверенности ≥ порога
Вопросы по статусу заказа / аккаунту	Нет (v2)	Требует CRM; в MVP недоступно
Медицинские, юридические темы	Нет	Всегда к оператору
Жалобы и претензии	Нет	Высокий риск, к оператору
Запрос на возврат средств	Нет	Требует авторизации действий
Нецензурная лексика / агрессия	Нет	Отдельный сценарий
Технические вопросы без ответа в базе	Нет	Низкая уверенность → к оператору

4. Вопросы к Product Manager / стейкхолдерам

ОБЯЗАТЕЛЬНО ДО СТАРТА РАЗРАБОТКИ

Q1

Порог уверенности

Какое минимальное значение достаточно? Кто устанавливает и пересматривает?

[ГИПОТЕЗА] 0.75; пересмотр по результатам пилота

Q2

Чувствительные темы

Кто ведёт список? Как добавляется новая тема?

—

Q3

Таймауты

Значения TYPING_INDICATOR_TIMEOUT и MAX_GENERATION_TIMEOUT?

[ГИПОТЕЗА] 5 сек и 15 сек

Q4

Дебаунс

Через сколько секунд считать паузу? Максимум сообщений в очереди?

[ГИПОТЕЗА] 2–3 сек

Q5

"Взял диалог"

Оператор открыл вкладку / нажал "Принять" / отправил первое сообщение?

—

Q6

Механизм недовольства

Кнопка оценки? Триггерная фраза? Повторный вопрос?

[ГИПОТЕЗА] Считать "недовольством" негативный сентимент в следующем сообщении ИЛИ нажатие 👎 — прошу подтвердить

Q7

Нерабочее время

Что получает клиент при эскалации ночью / в выходные? Автоответ? Только AI без эскалации?

[ГИПОТЕЗА] Автоответ "ответим в рабочее время" + диалог в очередь

Q8

Оператор и интерфейс

Нужна ли подсказка "Последний ответ дал AI"? Как оператор продолжает без повторения сказанного ботом?

—

Q9

SLA оператора

Есть ли максимальное время ответа после получения диалога? Что при превышении?

—

Q10

Аналитика

Какие метрики с первого дня?

% передач, P95 времени, точность

ЮРИДИЧЕСКИЕ ТРЕБОВАНИЯ И ПРИВАТНОСТЬ (PM + КОМПЛАЕНС)

Q11

Срок хранения логов AI-диалогов, кто имеет доступ?

Q12

Маскирование ПДн в логах (ФИО, телефон, email в текстах сообщений)?

Q13

Кто имеет доступ к "обоснованию" ответа AI (источник, скор уверенности)?

Q14

Необходимо ли согласование формулировок заглушек и автоответов с юридическим отделом?

5. Задача для разработки: MVP

НАЗВАНИЕ

[FEAT] AI-оператор: автоматические ответы в чате с управляемой передачей оператору — MVP

ПРОБЛЕМА / ЦЕЛЬ

Операторы перегружены типовыми обращениями. Клиенты ждут дольше допустимого. Необходим автоматический агент, снимающий нагрузку без ошибок на чувствительных темах и без дублирования работы живых операторов.

ОБЪЕМ MVP

Классификатор тем (чувствительная / нечувствительная)

`[MUST MVP]`

Генерация ответа по базе знаний

`[MUST MVP]`

Оценка уверенности и логика порога

`[MUST MVP]`

Дебаунсинг входящих сообщений

`[MUST MVP]`

Заглушка при долгой генерации

`[MUST MVP]`

Автопередача оператору при таймауте и низкой уверенности	[MUST MVP]
Взаимоисключение: блокировка AI при подключении оператора (FR-13)	[MUST MVP]
Кнопка "Позвать оператора" для клиента	[MUST MVP]
Отображение ответа AI + источника в интерфейсе оператора	[MUST MVP]
Автоответ при эскалации в нерабочее время	[MUST MVP]
Базовое логирование действий AI	[MUST MVP]
Настройка порогов через интерфейс	[ГИПОТЕЗА] → v1.1

Не входит в объем (MVP): интеграция с CRM, мультиканальность, автозакрытие диалога, дообучение модели, A/B-тестирование порогов, аналитический дашборд.

МЕТРИКИ УСПЕХА MVP

Доля автоматически закрытых диалогов	% диалогов без участия оператора	Базовый прогноз после 2 нед. пилота
Доля эскалаций	% диалогов, переданных оператору (любая причина)	Базовый прогноз после пилота
P95 времени ответа AI	95-й перцентиль времени от сообщения до ответа	≤ 10 сек
Доля ошибочных ответов по чувствительным темам	AI ответил там, где должен был передать оператору	0%
Среднее время первого ответа оператора после эскалации	После передачи диалога	Определяется по базовым данным

> Цели по снижению нагрузки и росту автоматизации — **гипотеза**, требует базового прогноза по историческим данным. Фиксируются как ориентиры по итогам пилота.

КЛЮЧЕВЫЕ ПАРАМЕТРЫ

`DEBOUNCE_TIMEOUT`

Пауза перед обработкой

2–3 сек `[ГИПОТЕЗА]`

`CONFIDENCE_THRESHOLD`

Минимальная уверенность AI

0.75 `[ГИПОТЕЗА]`

`TYPING_INDICATOR_TIMEOUT`

Таймаут до заглушки

5 сек `[ГИПОТЕЗА]`

`MAX_GENERATION_TIMEOUT`

Максимум генерации

15 сек `[ГИПОТЕЗА]`

КРИТЕРИИ ПРИЁМКИ

AC-01

Клиент отправил сообщение по чувствительной теме

AI не отвечает; диалог передаётся оператору с пометкой темы

AC-02

AI сформировал ответ с уверенностью < CONFIDENCE_THRESHOLD

Ответ не отправляется; диалог уходит оператору с черновиком и причиной

AC-03

Клиент отправил 3 сообщения с паузами < DEBOUNCE_TIMEOUT

Система ждёт; AI отвечает один раз на агрегированный контекст

AC-04

Генерация занимает > TYPING_INDICATOR_TIMEOUT

Клиент получает сообщение-заглушку

AC-05

Генерация занимает > MAX_GENERATION_TIMEOUT

Диалог автоматически передаётся оператору; AI останавливается

AC-06

Оператор нажал "Принять" или отправил первое сообщение

AI немедленно прекращает генерацию (взаимоисключение); новые ответы AI в этом диалоге не отправляются

AC-07

Клиент нажал "Позвать оператора"

AI останавливается; диалог передаётся оператору

AC-08

AI отправил ответ клиенту

Оператор видит ответ AI + источник из базы знаний в своём интерфейсе

AC-09

Любое действие AI (генерация, передача, таймаут)

Событие записывается в лог с меткой времени и ID диалога

AC-10

Система обрабатывает стандартный трафик

P95 времени от сообщения клиента до ответа AI ≤ 10 сек

AC-11*(негативный)*

Клиент отправил новое сообщение**во время генерации** ответа AI

Текущая генерация отменяется; запускается новый дебаунс с полным контекстом

AC-12*(негативный)*

Оператор открыл чат**после** ответа AI и написал продолжение

AI не генерирует; оператор видит историю с ответом AI и продолжает диалог без повторения

AC-13*(негативный)*

Инициирована эскалация, операторов нет в линии

Клиент получает автоответ с временем следующего ответа; диалог сохраняется в очереди

ТРАССИРОВКА FR → AC

FR-01, FR-02, FR-05

AC-01

Чувствительная тема → немедленно оператору

FR-03, FR-04

AC-02

Низкая уверенность → оператору с черновиком

FR-07

AC-03, AC-11

Дебаунсинг: агрегация сообщений и отмена генерации

FR-08

AC-04

Заглушка при долгой генерации

FR-09

AC-05

MAX_TIMEOUT → автоэскалация

FR-06, FR-13

AC-06, AC-12

Взаимоисключение: оператор взял → AI заблокирован

FR-10

AC-07

Кнопка "Позвать оператора"

FR-11, FR-12

AC-08, AC-12

Оператор видит историю AI

NFR-03

AC-09

Логирование всех действий AI

NFR-01

AC-10

P95 ≤ 10 сек

FR-14

AC-13

Нерабочее время — автоответ + очередь

ЗАВИСИМОСТИ И РИСКИ

Q1

Список чувствительных тем

Без него невозможен классификатор

PM

Q2

Значения таймаутов

Не согласованы; влияют на пользовательский опыт

PM + техлид

Q3

"Взял диалог"

Не определено событие-триггер взаимоисключение

PM + фронтенд

Q4

Механизм недовольства

Рабочая гипотеза: негативный сентимент ИЛИ 👎

PM

D1

База знаний

Качество ответов AI прямо зависит от полноты базы

Content-команда

D2	ML confidence score	FR-03 предполагает калиброванный скор от модели. Если скор недоступен — запасной вариант: только RAG + порог релевантности чанков ML-команда
R1	Галлюцинации AI	При низком пороге AI отвечает неточно A/B после MVP
R2	Перегрузка операторов	При высоком пороге все диалоги уйдут к людям Мониторинг с первого дня
R3	Состояние гонки	Закрыт FR-13 (взаимоисключение); требует ревью техлида техлид

ИЗМЕНЕНИЯ В РАБОЧЕМ ПРОЦЕССЕ ОПЕРАТОРА (УПРАВЛЕНИЕ ИЗМЕНЕНИЯМИ)

При внедрении AI-оператора рабочий процесс операторов изменится. До старта разработки необходимо уточнить с PM:

- Нужно ли обучение операторов новому интерфейсу?
- Как оператор понимает, что диалог уже обработан AI (явная метка в интерфейсе)?
- Нужна ли подсказка: *"Последний ответ клиенту дал AI"*?
- Как оператор продолжает диалог без повторения сказанного ботом?

Приложение A: Предложение по этапам развития

> Цифры по снижению нагрузки — **гипотезы**, подлежат подтверждению на пилоте по историческим данным.

MVP	Классификатор тем, генерация по базе знаний, порог уверенности, передача оператору, взаимоисключение	Базовая автоматизация; замер реального снижения нагрузки
v1.1	Кнопка оценки ответа AI клиентом, базовый аналитический дашборд, настройка порогов через интерфейс	Измерение качества; инструмент обратной связи для операторов
v2.0	Интеграция с CRM, персонализированные ответы, A/B-тесты порогов	Рост автоматизации; сокращение времени ответа

v3.0

Дообучение модели на исторических диалогах, мультиканальность

Умный оператор с памятью контекста клиента

Приложение Б: Визуальная схема потока

Б.1 ОБРАБОТКА СООБЩЕНИЯ AI

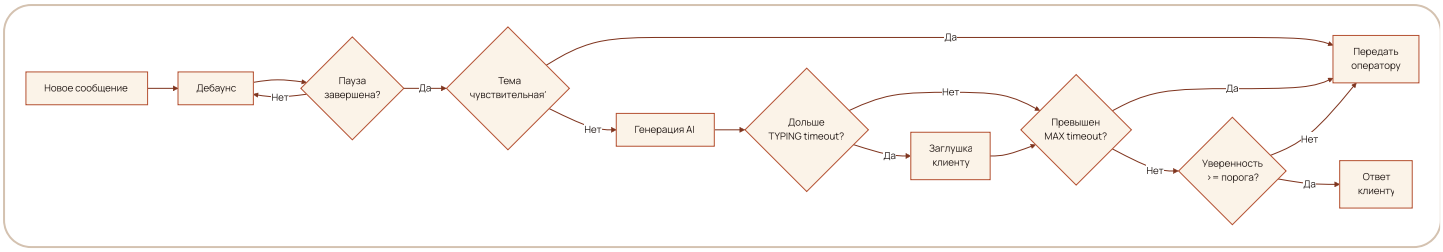
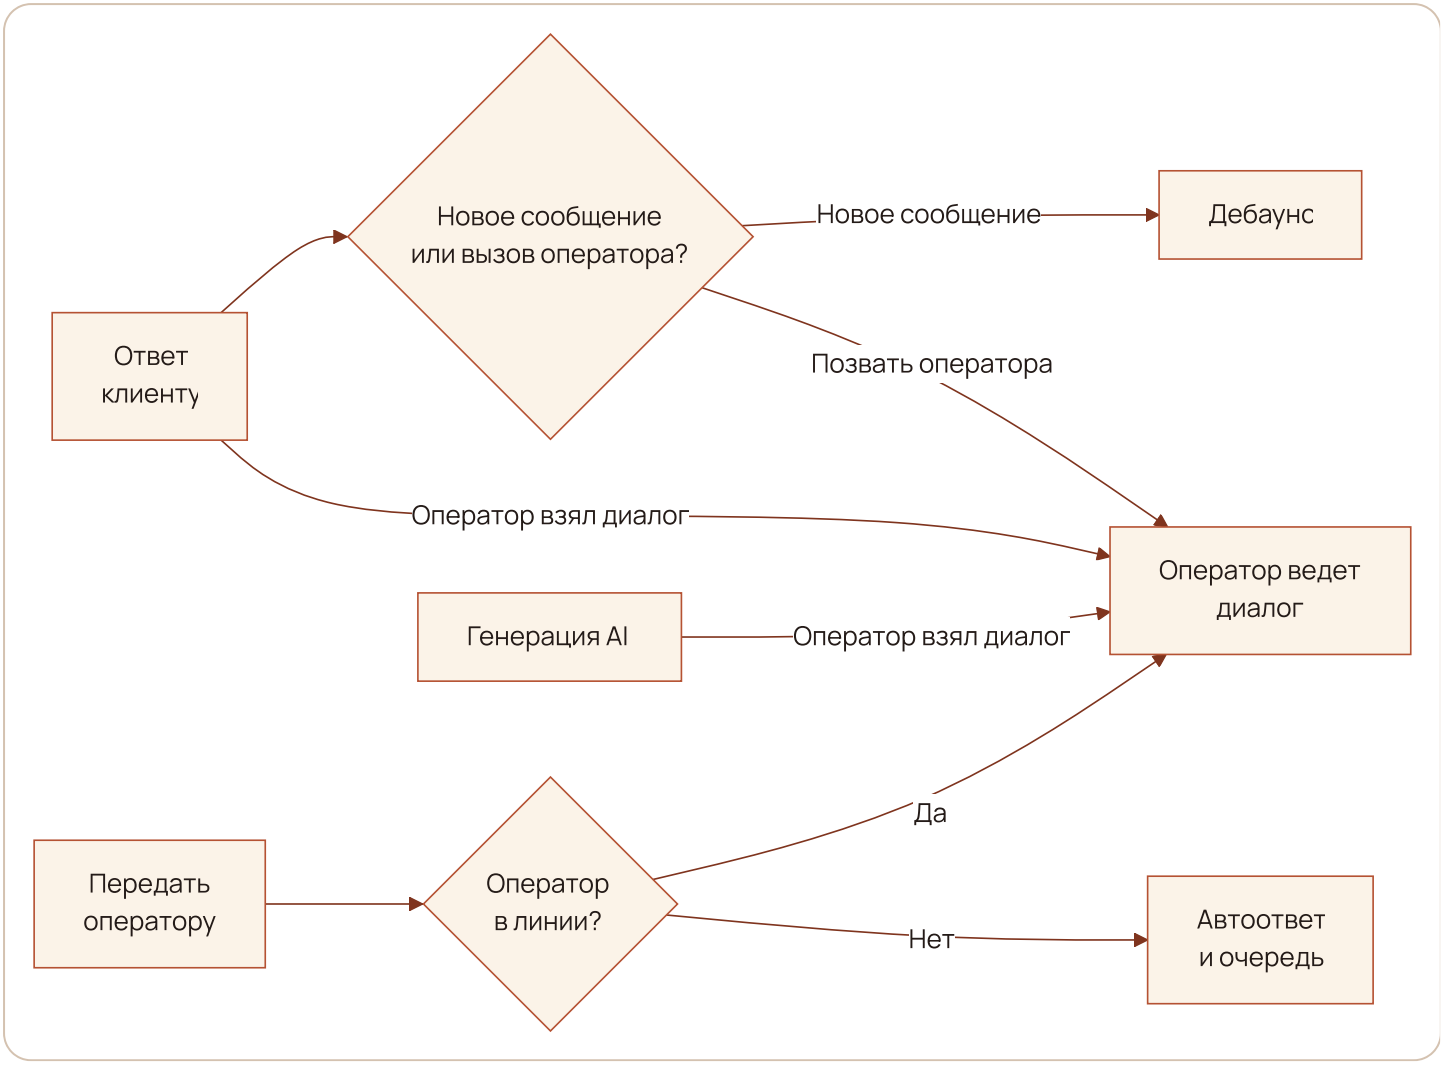
Б.2 ЭСКАЛАЦИЯ И ПРОДОЛЖЕНИЕ ДИАЛОГА