Аналитический документ: Логика AI-оператора

Дата: 2026-04-08 (rev. 1.2) **Автор:** Курганский Антон

0. Краткое резюме

Проблема исходного описания: ТЗ содержит внутренние противоречия — система одновременно "передаёт диалог оператору" и "продолжает отвечать AI", нет порога уверенности, таймаутов и механизма защиты от гонки состояний. В текущем виде реализация неизбежно приведёт к дублированию ответов, галлюцинациям AI и деградации клиентского опыта.

Ключевое решение: AI-оператор — первая линия обработки входящих сообщений. Он классифицирует обращение, генерирует ответ при достаточной уверенности и блокируется (взаимоисключение на уровне диалога) при подключении живого оператора. Оператор видит полный контекст работы AI.

Что входит в MVP:

- Классификатор тем (чувствительная / нечувствительная)
- Генерация ответа по базе знаний с порогом уверенности
- Дебаунсинг, таймауты, заглушка, автоэскалация
- Блокировка AI при подключении оператора (взаимоисключение)
- Кнопка "Позвать оператора" для клиента
- Отображение ответа AI + источника в интерфейсе оператора

Топ-5 открытых вопросов к PM:

1. Какой порог уверенности считается достаточным и кто его пересматривает?
2. Кто ведёт и обновляет список чувствительных тем?
3. Какие конкретные значения таймаутов (заглушка / максимум)?
4. Что означает "оператор взял диалог" — открыл вкладку, нажал "Принять" или отправил сообщение?
5. Что происходит при эскалации в нерабочее время — автоответ или только AI без эскалации?

1. Проблема и контекст

ЧТО РЕШАЕТ ФУНКЦИЯ

AI-оператор — автоматический агент, отвечающий клиентам вместо живого оператора. Цель: снизить нагрузку на поддержку, ускорить время ответа, обрабатывать типовые обращения без участия человека.

ПОЧЕМУ НЕЛЬЗЯ ОТДАВАТЬ В РАЗРАБОТКУ В ТЕКУЩЕМ ВИДЕ

1. **Конфликт управления диалогом** (п. 4 vs п. 5): система одновременно "передаёт диалог оператору" и "продолжает отвечать AI".
2. **Нет порога уверенности** (п. 3 и 6): AI будет галлюцинировать на чувствительных темах.
3. **Нет таймаута на генерацию** (п. 8): "клиент просто ждёт" противоречит требованию "не должен долго оставаться без ответа".
4. **Нет механизма недовольства** (п. 9): неясно, что триггерит подключение оператора.
5. **Оператор слеп к логике рассуждений AI** (п. 10): риск продолжить некачественный ответ.
6. **Проблема синхронизации** (п. 7): ответы на каждое сообщение по отдельности приведут к дублированию.

2. Требования к системе

2.1 ФУНКЦИОНАЛЬНЫЕ ТРЕБОВАНИЯ

FR-01

`[MUST MVP]`

Система определяет**тип обращения** до генерации ответа (чувствительная тема / типовой вопрос / нераспознанный).

FR-02

`[MUST MVP]`

AI генерирует ответ только если обращение**не относится к чувствительным темам**.

FR-03

`[MUST MVP]`

AI отправляет ответ клиенту только если**уверенность модели ≥ CONFIDENCE_THRESHOLD**. Конкретное значение порога — `[ГИПОТЕЗА]`, согласуется с PM и ML-командой после анализа распределения скоров.

FR-04

`[MUST MVP]`

Если уверенность < порога —**диалог передаётся оператору** с черновиком ответа AI и причиной.

FR-05

`[MUST MVP]`

Если тема чувствительная —**AI не отвечает**, диалог немедленно уходит оператору с пометкой темы.

FR-06

`[MUST MVP]`

Как только**оператор взял диалог** — AI **прекращает генерацию** по этому диалогу.

FR-07

`[MUST MVP]`

При нескольких сообщениях подряд с паузой < DEBOUNCE_TIMEOUT — AI**ждёт паузы** и отвечает на агрегированный контекст.

FR-08

`[MUST MVP]`

Если генерация > TYPING_INDICATOR_TIMEOUT — клиенту отправляется**заглушка**: "Мы уже изучаем ваш вопрос, ответим через несколько секунд".

FR-09

`[MUST MVP]`

Если генерация > MAX_GENERATION_TIMEOUT — диалог**автоматически передаётся оператору**.

FR-10

`[MUST MVP]`

Клиент может**явно запросить оператора** (кнопка или фраза-триггер) — AI останавливается, диалог уходит оператору.

FR-11

`[MUST MVP]`

Оператор видит**ответ AI + источник из базы знаний / причину передачи**.

FR-12

`[MUST MVP]`

Оператор**не дублирует ответ AI**: видит историю и продолжает диалог с учётом уже сказанного.

FR-13

`[MUST MVP]`

При событии "оператор взял диалог" —**отменить незавершенную генерацию**, запретить отправку уже сформированного буфера. Диалог блокируется для AI (взаимоисключение на уровне диалога).

FR-14

`[MUST MVP]`

При эскалации в нерабочее время (нет операторов в линии) — клиент получает**автоответ** с временем следующего ответа; диалог сохраняется в очереди. *(Конкретная формулировка — `[ГИПОТЕЗА]`, согласуется с PM.)*

2.2 НЕФУНКЦИОНАЛЬНЫЕ ТРЕБОВАНИЯ

NFR-01

`[MUST MVP]`

Время ответа AI — не более**10 сек** в 95% случаев (P95).

NFR-02

`[MUST MVP]`

Конкурентная обработка диалогов без взаимного влияния (изолированные очереди).

NFR-03

`[MUST MVP]`

Все действия AI логируются с меткой времени, ID диалога и причиной.

NFR-04

`[ГИПОТЕЗА]`

Архитектура позволяет подключить CRM в v2 без переписывания ядра.

> **Явная граница MVP:** AI работает только с базой знаний. Персональные данные клиента из CRM недоступны (реализация в v2).

3. Целевая логика работы

3.1 ТЕКСТОВОЕ ОПИСАНИЕ

1. Клиент отправляет сообщение.
2. Система ожидает паузу DEBOUNCE_TIMEOUT — если клиент продолжает набирать, ждёт окончания.
3. Классификация обращения:
   - **Чувствительная тема** → немедленно оператору с пометкой; AI не отвечает.
   - **Обычный вопрос** → AI начинает генерацию.
4. Если генерация > TYPING_INDICATOR_TIMEOUT → клиенту отправляется заглушка.
5. Если генерация > MAX_GENERATION_TIMEOUT → оператору; AI останавливается.
6. Оценка уверенности:
   - **≥ порога** → ответ клиенту; оператор видит ответ + источник.

- ‹ **порога** → оператору с черновиком.

7. Если **оператор взял диалог** — немедленное взаимоисключение: незавершенная генерация отменяется, AI блокируется.
8. Клиент может в любой момент нажать "Позвать оператора" → AI останавливается.
9. При эскалации без операторов в линии → автоответ клиенту, диалог в очередь.

3.2 КОМПАКТНАЯ СХЕМА СОСТОЯНИЙ (MERMAID)

Подробная визуальная схема потока приведена в **Приложении Б**.

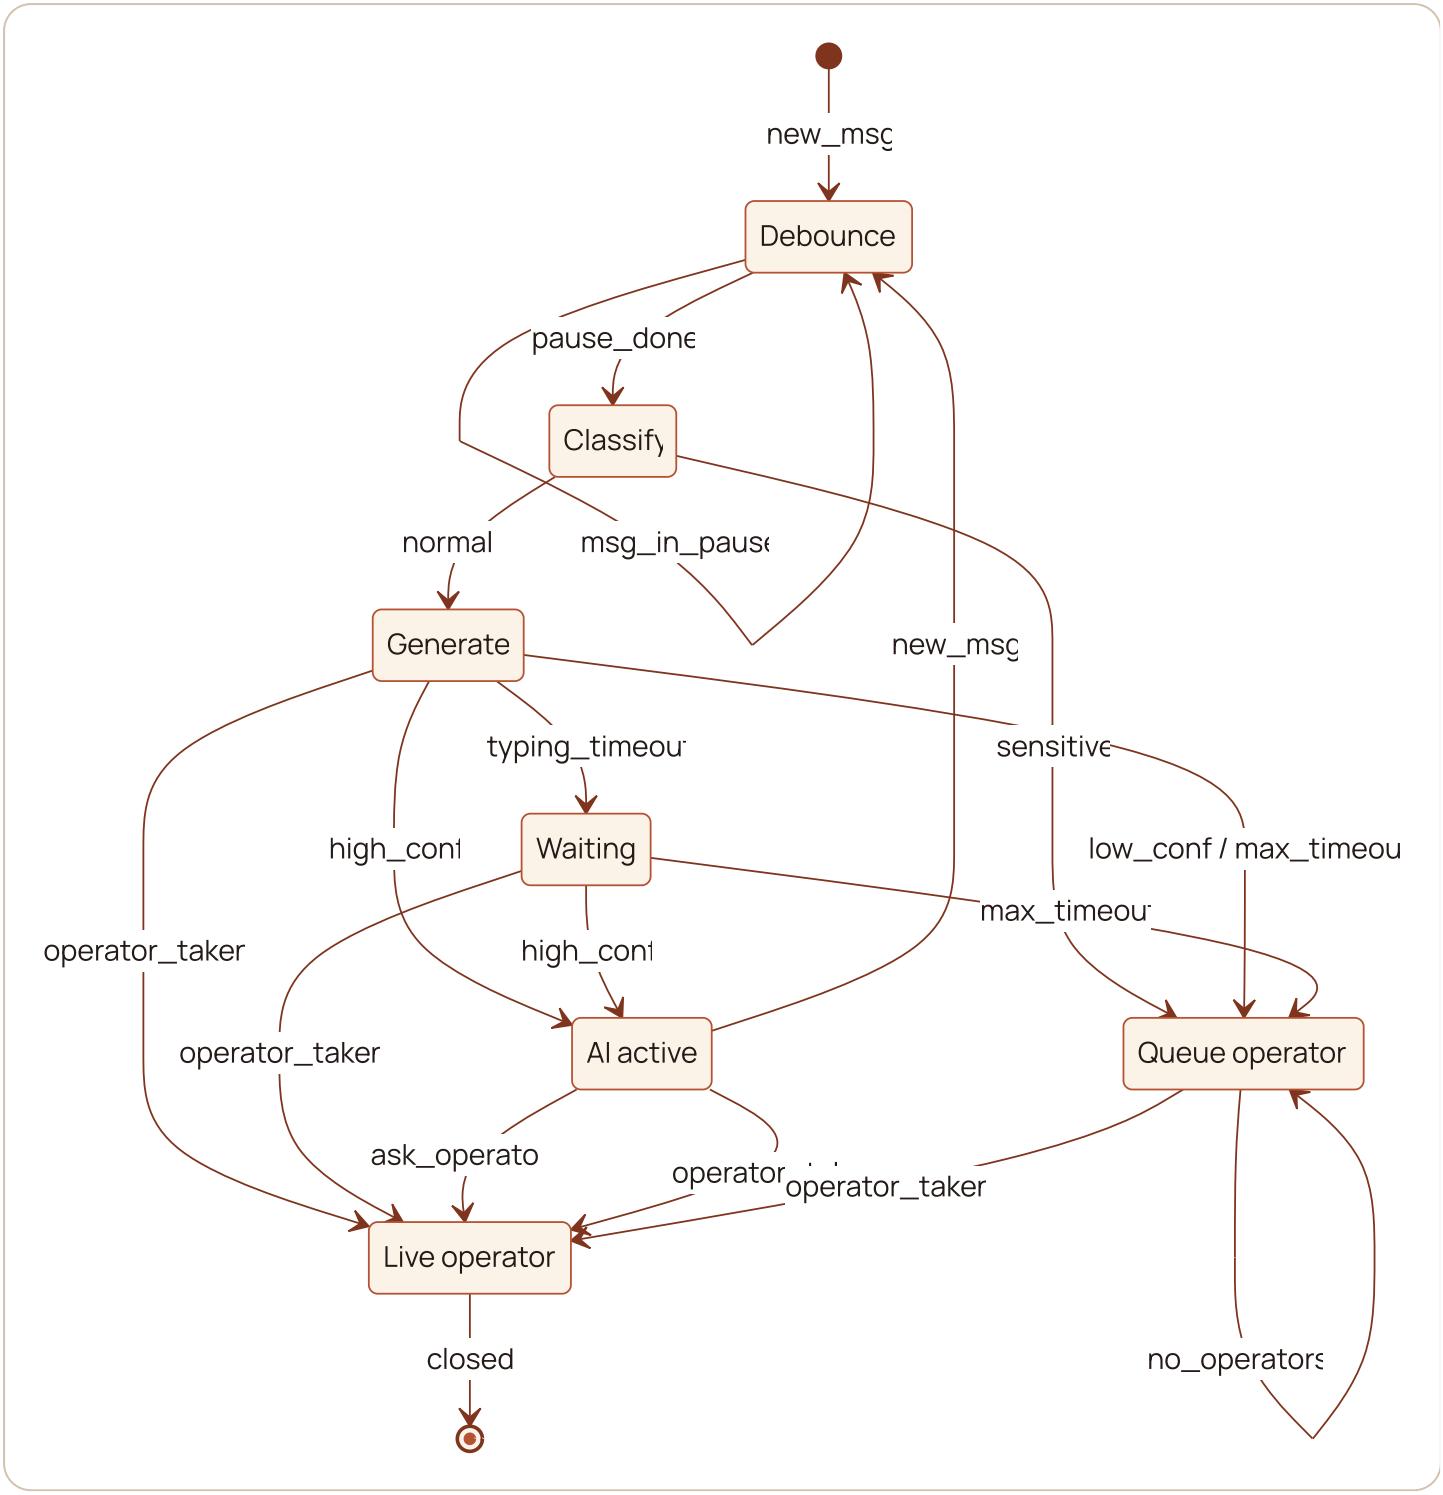

3.3 ТАБЛИЦА СОСТОЯНИЙ И ДОПУСТИМЫХ ПЕРЕХОДОВ

`[*] / AI_ACTIVE`	
`DEBOUNCING`	
получено сообщение клиента	

`DEBOUNCING`	`DEBOUNCING`
новое сообщение в пределах DEBOUNCE_TIMEOUT	
`DEBOUNCING`	`CLASSIFYING`
пауза ≥ DEBOUNCE_TIMEOUT	
`CLASSIFYING`	`OPERATOR_PENDING`
тема = чувствительная	
`CLASSIFYING`	`AI_GENERATING`
тема = обычная / нераспознанная	
`AI_GENERATING`	`AI_WAITING`
генерация > TYPING_INDICATOR_TIMEOUT	
`AI_GENERATING`	`OPERATOR_PENDING`
генерация > MAX_GENERATION_TIMEOUT ИЛИ уверенность < порога	
`AI_GENERATING`	`AI_ACTIVE`
уверенность ≥ порога, ответ отправлен	
`AI_GENERATING`	`OPERATOR_ACTIVE`
оператор взял диалог (взаимоисключение → генерация отменена)	
`AI_WAITING`	`OPERATOR_PENDING`
генерация > MAX_GENERATION_TIMEOUT	
`AI_WAITING`	`AI_ACTIVE`
уверенность ≥ порога, ответ отправлен	
`AI_WAITING`	`OPERATOR_ACTIVE`
оператор взял диалог (взаимоисключение → генерация отменена)	
`AI_ACTIVE`	`DEBOUNCING`
новое сообщение клиента	

`AI_ACTIVE`	`OPERATOR_ACTIVE`	клиент нажал "Позвать оператора" ИЛИ оператор взял диалог
`OPERATOR_PENDING`	`OPERATOR_ACTIVE`	оператор взял диалог
`OPERATOR_PENDING`	`OPERATOR_PENDING`	нет операторов → автоответ клиенту
`OPERATOR_ACTIVE`	`[*]`	оператор закрыл диалог

3.4 ЧТО AI ОБРАБАТЫВАЕТ / НЕ ОБРАБАТЫВАЕТ

FAQ, типовые вопросы по продукту	Да	При уверенности ≥ порога
Вопросы по статусу заказа / аккаунту	Нет (v2)	Требует CRM; в MVP недоступно
Медицинские, юридические темы	Нет	Всегда к оператору
Жалобы и претензии	Нет	Высокий риск, к оператору
Запрос на возврат средств	Нет	Требует авторизации действий
Нецензурная лексика / агрессия	Нет	Отдельный сценарий
Технические вопросы без ответа в базе	Нет	Низкая уверенность → к оператору

4. Вопросы к Product Manager / стейкхолдерам

ОБЯЗАТЕЛЬНО ДО СТАРТА РАЗРАБОТКИ

Q1

Порог уверенности

Какое минимальное значение достаточно? Кто устанавливает и пересматривает?

[ГИПОТЕЗА] 0.75; пересмотр по результатам пилота

Q2

Чувствительные темы

Кто ведёт список? Как добавляется новая тема?

—

Q3

Таймауты

Значения TYPING_INDICATOR_TIMEOUT и MAX_GENERATION_TIMEOUT?

[ГИПОТЕЗА] 5 сек и 15 сек

Q4

Дебаунс

Через сколько секунд считать паузу? Максимум сообщений в очереди?

[ГИПОТЕЗА] 2–3 сек

Q5

"Взял диалог"

Оператор открыл вкладку / нажал "Принять" / отправил первое сообщение?

—

Q6

Механизм недовольства

Кнопка оценки? Триггерная фраза? Повторный вопрос?

[ГИПОТЕЗА] Считать "недовольством" негативный сентимент в следующем сообщении ИЛИ нажатие 👎 — прошу подтвердить

Q7

Нерабочее время

Что получает клиент при эскалации ночью / в выходные? Автоответ? Только AI без эскалации?

[ГИПОТЕЗА] Автоответ "ответим в рабочее время" + диалог в очередь

Q8

Оператор и интерфейс

Нужна ли подсказка "Последний ответ дал AI"? Как оператор продолжает без повторения сказанного ботом?

—

Q9

SLA оператора

Есть ли максимальное время ответа после получения диалога? Что при превышении?

—

Q10

Аналитика

Какие метрики с первого дня?

% передач, P95 времени, точность

ЮРИДИЧЕСКИЕ ТРЕБОВАНИЯ И ПРИВАТНОСТЬ (PM + КОМПЛАЕНС)

Q11

Срок хранения логов AI-диалогов, кто имеет доступ?

Q12

Маскирование ПДн в логах (ФИО, телефон, email в текстах сообщений)?

Q13

Кто имеет доступ к "обоснованию" ответа AI (источник, скор уверенности)?

Q14

Необходимо ли согласование формулировок заглушек и автоответов с юридическим отделом?

5. Задача для разработки: MVP

НАЗВАНИЕ

[FEAT] AI-оператор: автоматические ответы в чате с управляемой передачей оператору — MVP

ПРОБЛЕМА / ЦЕЛЬ

Операторы перегружены типовыми обращениями. Клиенты ждут дольше допустимого. Необходим автоматический агент, снимающий нагрузку без ошибок на чувствительных темах и без дублирования работы живых операторов.

ОБЪЕМ MVP

Классификатор тем (чувствительная / нечувствительная)

`[MUST MVP]`

Генерация ответа по базе знаний

`[MUST MVP]`

Оценка уверенности и логика порога

`[MUST MVP]`

Дебаунсинг входящих сообщений

`[MUST MVP]`

Заглушка при долгой генерации

`[MUST MVP]`

Автопередача оператору при таймауте и низкой уверенности	[MUST MVP]
Взаимоисключение: блокировка AI при подключении оператора (FR-13)	[MUST MVP]
Кнопка "Позвать оператора" для клиента	[MUST MVP]
Отображение ответа AI + источника в интерфейсе оператора	[MUST MVP]
Автоответ при эскалации в нерабочее время	[MUST MVP]
Базовое логирование действий AI	[MUST MVP]
Настройка порогов через интерфейс	[ГИПОТЕЗА] → v1.1

Не входит в объем (MVP): интеграция с CRM, мультиканальность, автозакрытие диалога, дообучение модели, A/B-тестирование порогов, аналитический дашборд.

МЕТРИКИ УСПЕХА MVP

Доля автоматически закрытых диалогов	% диалогов без участия оператора	Базовый прогноз после 2 нед. пилота
Доля эскалаций	% диалогов, переданных оператору (любая причина)	Базовый прогноз после пилота
P95 времени ответа AI	95-й перцентиль времени от сообщения до ответа	≤ 10 сек
Доля ошибочных ответов по чувствительным темам	AI ответил там, где должен был передать оператору	0%
Среднее время первого ответа оператора после эскалации	После передачи диалога	Определяется по базовым данным

> Цели по снижению нагрузки и росту автоматизации — **гипотеза**, требует базового прогноза по историческим данным. Фиксируются как ориентиры по итогам пилота.

КЛЮЧЕВЫЕ ПАРАМЕТРЫ

`DEBOUNCE_TIMEOUT`

Пауза перед обработкой

2–3 сек `[ГИПОТЕЗА]`

`CONFIDENCE_THRESHOLD`

Минимальная уверенность AI

0.75 `[ГИПОТЕЗА]`

`TYPING_INDICATOR_TIMEOUT`

Таймаут до заглушки

5 сек `[ГИПОТЕЗА]`

`MAX_GENERATION_TIMEOUT`

Максимум генерации

15 сек `[ГИПОТЕЗА]`

КРИТЕРИИ ПРИЁМКИ

AC-01

Клиент отправил сообщение по чувствительной теме

AI не отвечает; диалог передаётся оператору с пометкой темы

AC-02

AI сформировал ответ с уверенностью < CONFIDENCE_THRESHOLD

Ответ не отправляется; диалог уходит оператору с черновиком и причиной

AC-03

Клиент отправил 3 сообщения с паузами < DEBOUNCE_TIMEOUT

Система ждёт; AI отвечает один раз на агрегированный контекст

AC-04

Генерация занимает > TYPING_INDICATOR_TIMEOUT

Клиент получает сообщение-заглушку

AC-05

Генерация занимает > MAX_GENERATION_TIMEOUT

Диалог автоматически передаётся оператору; AI останавливается

AC-06

Оператор нажал "Принять" или отправил первое сообщение

AI немедленно прекращает генерацию (взаимоисключение); новые ответы AI в этом диалоге не отправляются

AC-07

Клиент нажал "Позвать оператора"

AI останавливается; диалог передаётся оператору

AC-08

AI отправил ответ клиенту

Оператор видит ответ AI + источник из базы знаний в своём интерфейсе

AC-09

Любое действие AI (генерация, передача, таймаут)

Событие записывается в лог с меткой времени и ID диалога

AC-10

Система обрабатывает стандартный трафик

P95 времени от сообщения клиента до ответа AI ≤ 10 сек

AC-11*(негативный)*

Клиент отправил новое сообщение**во время генерации** ответа AI

Текущая генерация отменяется; запускается новый дебаунс с полным контекстом

AC-12*(негативный)*

Оператор открыл чат**после** ответа AI и написал продолжение

AI не генерирует; оператор видит историю с ответом AI и продолжает диалог без повторения

AC-13*(негативный)*

Инициирована эскалация, операторов нет в линии

Клиент получает автоответ с временем следующего ответа; диалог сохраняется в очереди

ТРАССИРОВКА FR → AC

FR-01, FR-02, FR-05

AC-01

Чувствительная тема → немедленно оператору

FR-03, FR-04

AC-02

Низкая уверенность → оператору с черновиком

FR-07

AC-03, AC-11

Дебаунсинг: агрегация сообщений и отмена генерации

FR-08

AC-04

Заглушка при долгой генерации

FR-09

AC-05

MAX_TIMEOUT → автоэскалация

FR-06, FR-13

AC-06, AC-12

Взаимоисключение: оператор взял → AI заблокирован

FR-10

AC-07

Кнопка "Позвать оператора"

FR-11, FR-12

AC-08, AC-12

Оператор видит историю AI

NFR-03

AC-09

Логирование всех действий AI

NFR-01

AC-10

P95 ≤ 10 сек

FR-14

AC-13

Нерабочее время — автоответ + очередь

ЗАВИСИМОСТИ И РИСКИ

Q1

Список чувствительных тем

Без него невозможен классификатор

PM

Q2

Значения таймаутов

Не согласованы; влияют на пользовательский опыт

PM + техлид

Q3

"Взял диалог"

Не определено событие-триггер взаимоисключение

PM + фронтенд

Q4

Механизм недовольства

Рабочая гипотеза: негативный сентимент ИЛИ 👎

PM

D1

База знаний

Качество ответов AI прямо зависит от полноты базы

Content-команда

D2	ML confidence score	FR-03 предполагает калиброванный скор от модели. Если скор недоступен — запасной вариант: только RAG + порог релевантности чанков ML-команда
R1	Галлюцинации AI	При низком пороге AI отвечает неточно A/B после MVP
R2	Перегрузка операторов	При высоком пороге все диалоги уйдут к людям Мониторинг с первого дня
R3	Состояние гонки	Закрыт FR-13 (взаимоисключение); требует ревью техлида техлид

ИЗМЕНЕНИЯ В РАБОЧЕМ ПРОЦЕССЕ ОПЕРАТОРА (УПРАВЛЕНИЕ ИЗМЕНЕНИЯМИ)

При внедрении AI-оператора рабочий процесс операторов изменится. До старта разработки необходимо уточнить с PM:

- Нужно ли обучение операторов новому интерфейсу?
- Как оператор понимает, что диалог уже обработан AI (явная метка в интерфейсе)?
- Нужна ли подсказка: *"Последний ответ клиенту дал AI"*?
- Как оператор продолжает диалог без повторения сказанного ботом?

Приложение A: Предложение по этапам развития

> Цифры по снижению нагрузки — **гипотезы**, подлежат подтверждению на пилоте по историческим данным.

MVP	Классификатор тем, генерация по базе знаний, порог уверенности, передача оператору, взаимоисключение	Базовая автоматизация; замер реального снижения нагрузки
v1.1	Кнопка оценки ответа AI клиентом, базовый аналитический дашборд, настройка порогов через интерфейс	Измерение качества; инструмент обратной связи для операторов
v2.0	Интеграция с CRM, персонализированные ответы, A/B-тесты порогов	Рост автоматизации; сокращение времени ответа

v3.0

Дообучение модели на исторических диалогах, мультиканальность

Умный оператор с памятью контекста клиента

Приложение Б: Визуальная схема потока

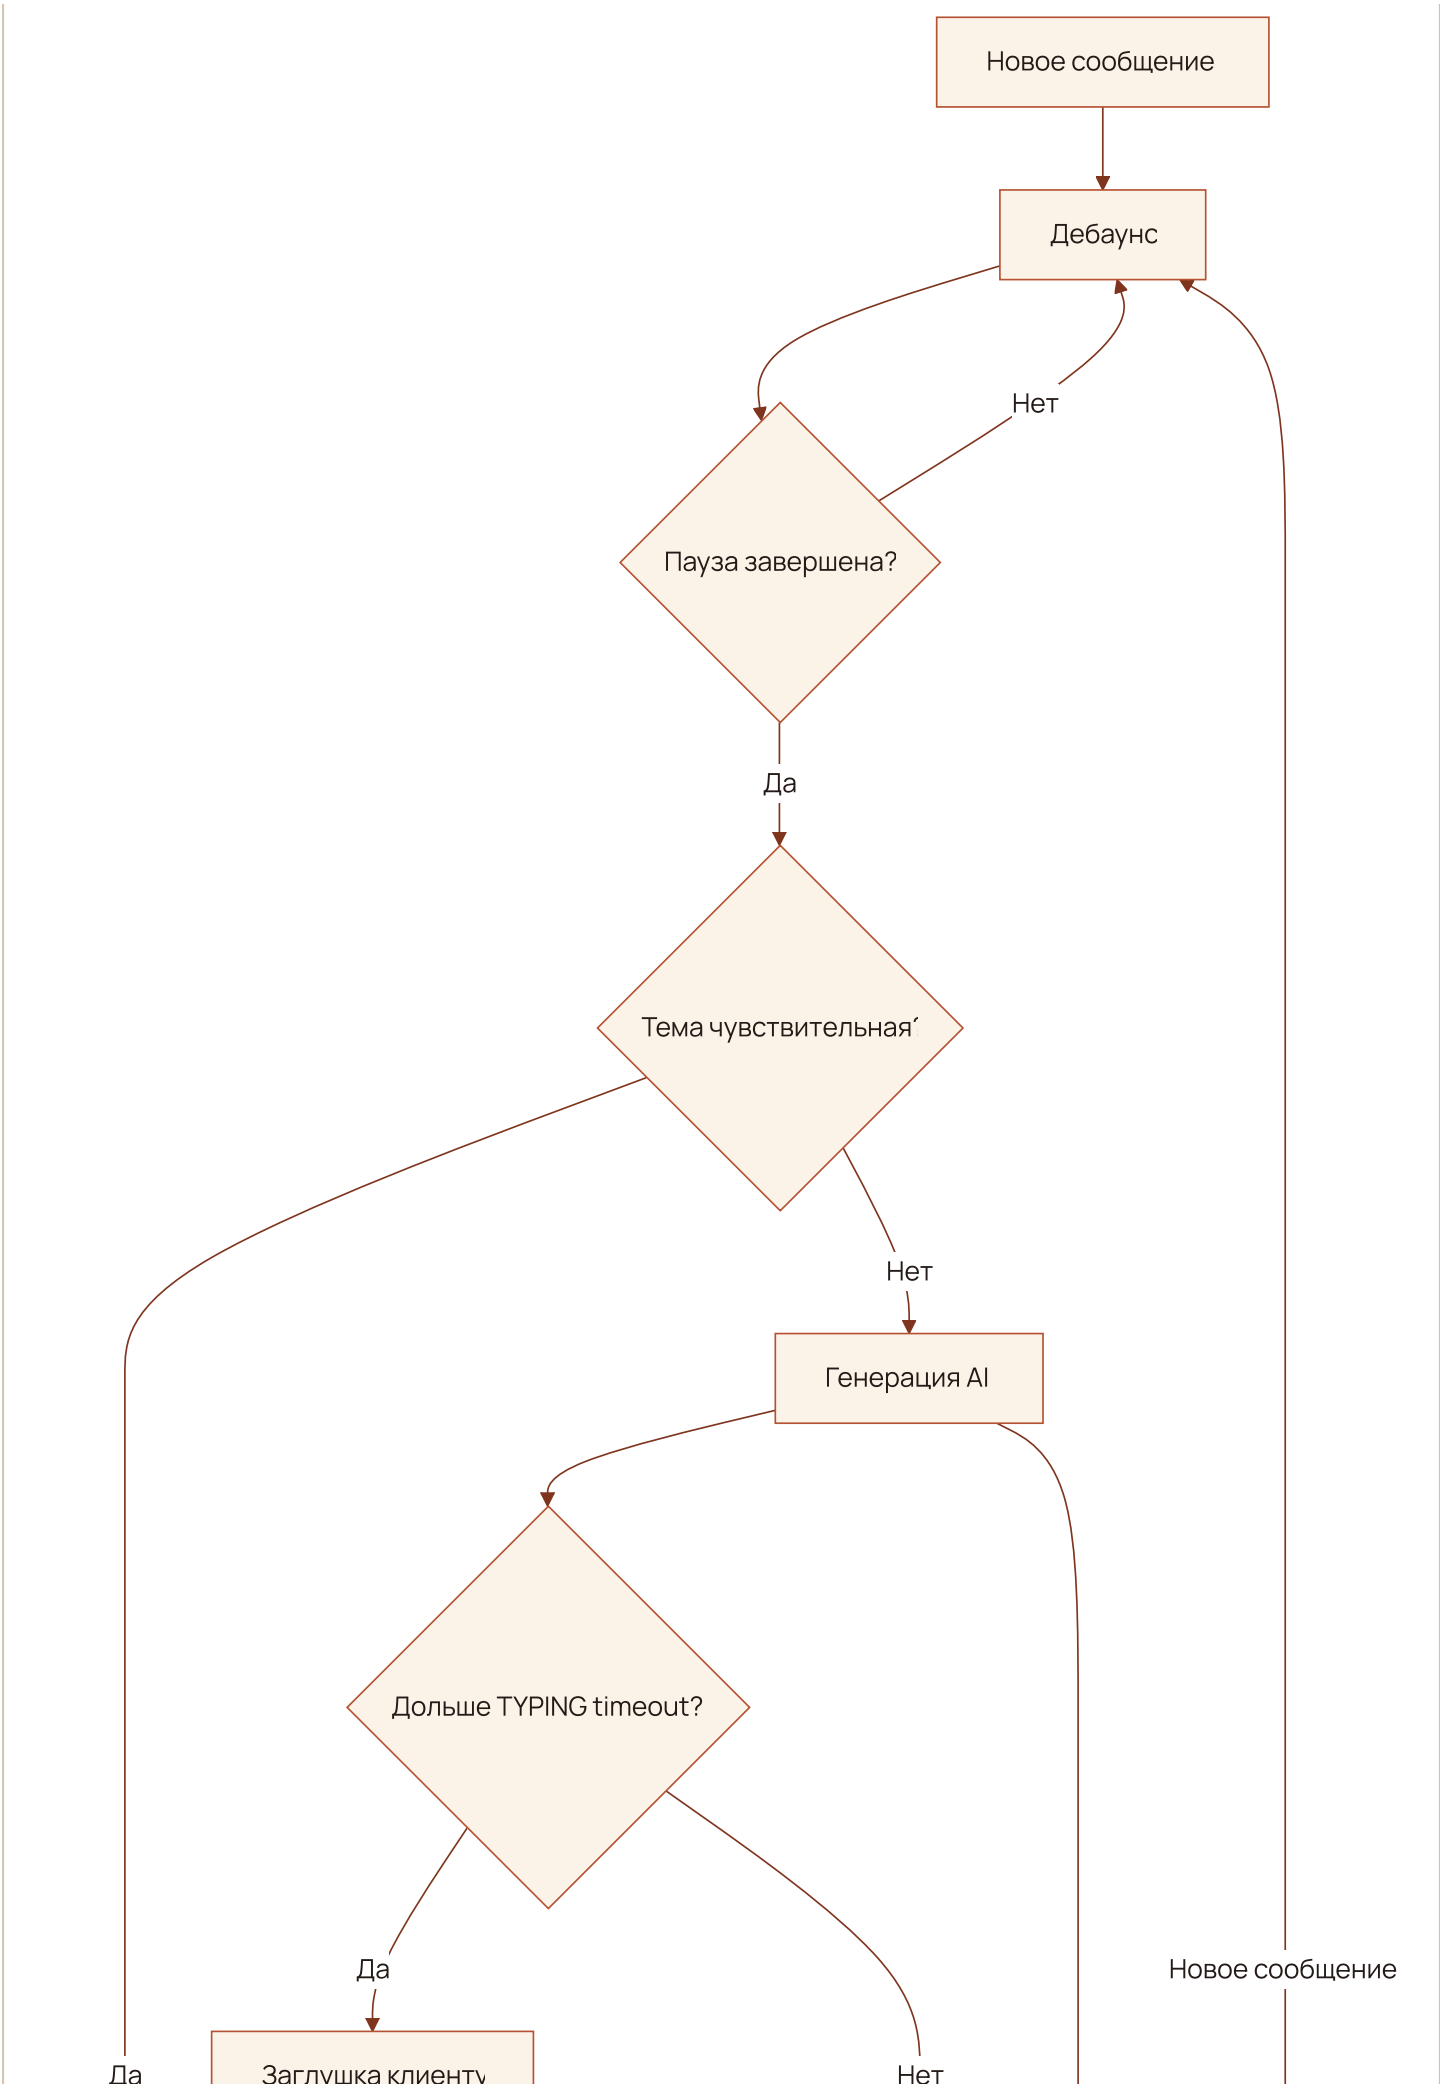
Новое сообщение
Дебаунс
Нет
Пауза завершена?
Да
Тема чувствительная'
Нет
Генерация AI
Дольше TYPING timeout?
Да
Новое сообщение
Да
Заглушка клиенту
Нет

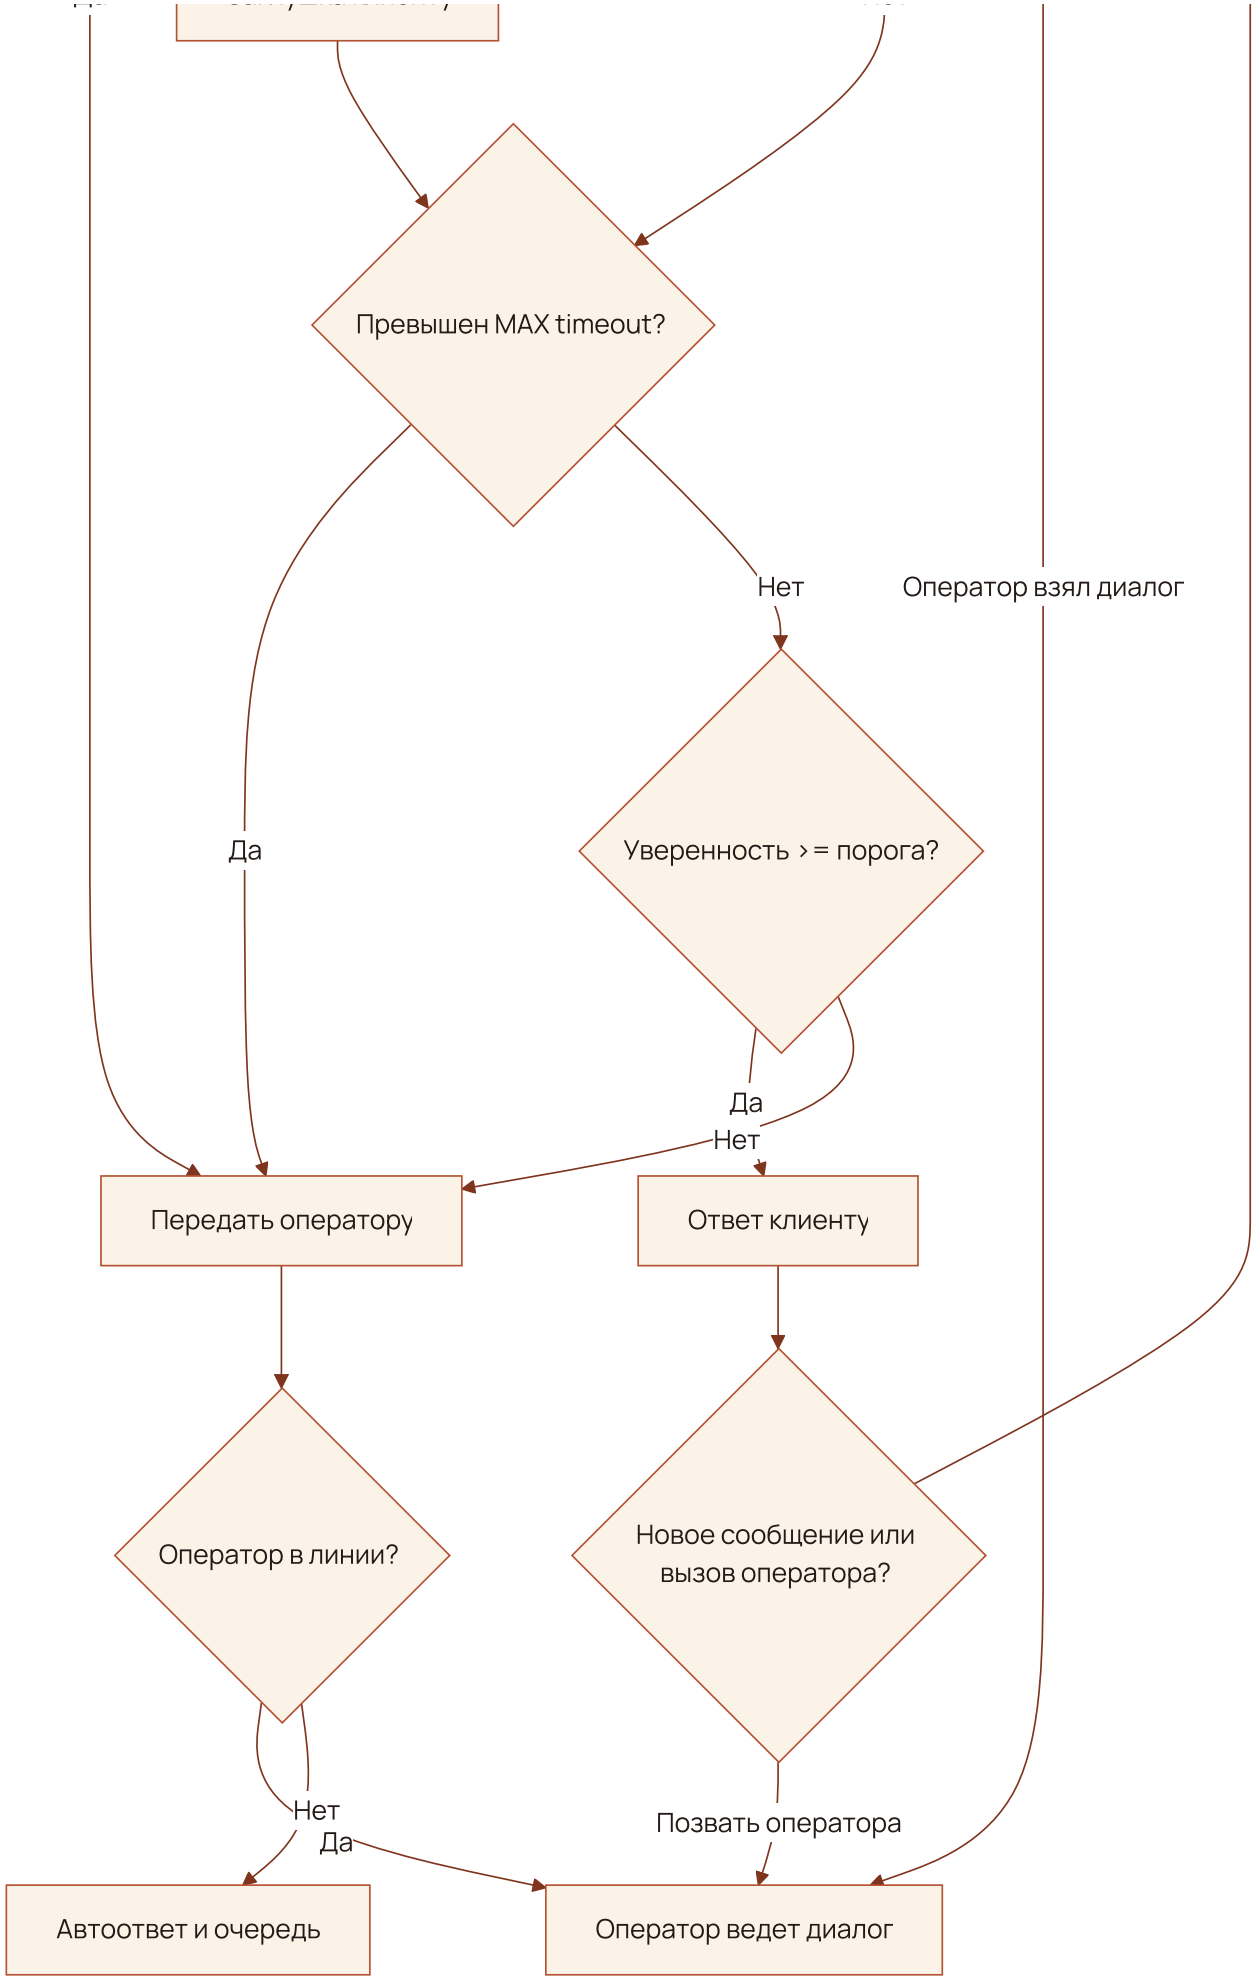
Превышен MAX timeout?
Нет
Оператор взял диалог
Да
Уверенность >= порога?
Да
Нет
Передать оператору
Ответ клиенту
Оператор в линии?
Новое сообщение или вызов оператора?
Нет
Да
Позвать оператора
Автоответ и очередь
Оператор ведет диалог