Аналитический документ: Логика AI-оператора

Дата: 2026-04-08 (rev. 1.2) **Автор:** Курганский Антон

0. Краткое резюме

Проблема исходного описания: ТЗ содержит внутренние противоречия — система одновременно "передаёт диалог оператору" и "продолжает отвечать AI", нет порога уверенности, таймаутов и механизма защиты от гонки состояний. В текущем виде реализация неизбежно приведёт к дублированию ответов, галлюцинациям AI и деградации клиентского опыта.

Ключевое решение: AI-оператор — первая линия обработки входящих сообщений. Он классифицирует обращение, генерирует ответ при достаточной уверенности и блокируется (взаимоисключение на уровне диалога) при подключении живого оператора. Оператор видит полный контекст работы AI.

Что входит в MVP:

- Классификатор тем (чувствительная / нечувствительная)
- Генерация ответа по базе знаний с порогом уверенности
- Дебаунсинг, таймауты, заглушка, автоэскалация
- Блокировка AI при подключении оператора (взаимоисключение)
- Кнопка "Позвать оператора" для клиента
- Отображение ответа AI + источника в интерфейсе оператора

Топ-5 открытых вопросов к PM:

1. Какой порог уверенности считается достаточным и кто его пересматривает?
2. Кто ведёт и обновляет список чувствительных тем?
3. Какие конкретные значения таймаутов (заглушка / максимум)?
4. Что означает "оператор взял диалог" — открыл вкладку, нажал "Принять" или отправил сообщение?
5. Что происходит при эскалации в нерабочее время — автоответ или только AI без эскалации?

1. Проблема и контекст

ЧТО РЕШАЕТ ФУНКЦИЯ

AI-оператор — автоматический агент, отвечающий клиентам вместо живого оператора. Цель: снизить нагрузку на поддержку, ускорить время ответа, обрабатывать типовые обращения без участия человека.

ПОЧЕМУ НЕЛЬЗЯ ОТДАВАТЬ В РАЗРАБОТКУ В ТЕКУЩЕМ ВИДЕ

1. **Конфликт управления диалогом** (п. 4 vs п. 5): система одновременно "передаёт диалог оператору" и "продолжает отвечать AI".
2. **Нет порога уверенности** (п. 3 и 6): AI будет галлюцинировать на чувствительных темах.
3. **Нет таймаута на генерацию** (п. 8): "клиент просто ждёт" противоречит требованию "не должен долго оставаться без ответа".
4. **Нет механизма недовольства** (п. 9): неясно, что триггерит подключение оператора.
5. **Оператор слеп к логике рассуждений AI** (п. 10): риск продолжить некачественный ответ.
6. **Проблема синхронизации** (п. 7): ответы на каждое сообщение по отдельности приведут к дублированию.

2. Требования к системе

2.1 ФУНКЦИОНАЛЬНЫЕ ТРЕБОВАНИЯ

ID	Приоритет	Требование
FR-01	`[MUST MVP]`	Система определяет**тип обращения** до генерации ответа (чувствительная тема / типовой вопрос / нераспознанный).
FR-02	`[MUST MVP]`	AI генерирует ответ только если обращение**не относится к чувствительным темам**.
FR-03	`[MUST MVP]`	AI отправляет ответ клиенту только если**уверенность модели ≥ CONFIDENCE_THRESHOLD**. Конкретное значение порога — `[ГИПОТЕЗА]`, согласуется с PM и ML-командой после анализа распределения скоров.
FR-04	`[MUST MVP]`	Если уверенность < порога —**диалог передаётся оператору** с черновиком ответа AI и причиной.
FR-05	`[MUST MVP]`	Если тема чувствительная —**AI не отвечает**, диалог немедленно уходит оператору с пометкой темы.
FR-06	`[MUST MVP]`	Как только**оператор взял диалог** — AI **прекращает генерацию** по этому диалогу.
FR-07	`[MUST MVP]`	При нескольких сообщениях подряд с паузой < DEBOUNCE_TIMEOUT — AI**ждёт паузы** и отвечает на агрегированный контекст.
FR-08	`[MUST MVP]`	Если генерация > TYPING_INDICATOR_TIMEOUT — клиенту отправляется**заглушка**: "Мы уже изучаем ваш вопрос, ответим через несколько секунд".
FR-09	`[MUST MVP]`	Если генерация > MAX_GENERATION_TIMEOUT — диалог**автоматически передаётся оператору**.
FR-10	`[MUST MVP]`	Клиент может**явно запросить оператора** (кнопка или фраза-триггер) — AI останавливается, диалог уходит оператору.
FR-11	`[MUST MVP]`	Оператор видит**ответ AI + источник из базы знаний / причину передачи**.
FR-12	`[MUST MVP]`	Оператор**не дублирует ответ AI**: видит историю и продолжает диалог с учётом уже сказанного.
FR-13	`[MUST MVP]`	При событии "оператор взял диалог" —**отменить незавершенную генерацию**, запретить отправку уже сформированного буфера. Диалог блокируется для AI (взаимоисключение на уровне диалога).
FR-14	`[MUST MVP]`	При эскалации в нерабочее время (нет операторов в линии) — клиент получает**автоответ** с временем следующего ответа; диалог сохраняется в очереди. *(Конкретная формулировка — `[ГИПОТЕЗА]`, согласуется с PM.)*

2.2 НЕФУНКЦИОНАЛЬНЫЕ ТРЕБОВАНИЯ

ID	Приоритет	Требование
NFR-01	`[MUST MVP]`	Время ответа AI — не более**10 сек** в 95% случаев (P95).
NFR-02	`[MUST MVP]`	Конкурентная обработка диалогов без взаимного влияния (изолированные очереди).
NFR-03	`[MUST MVP]`	Все действия AI логируются с меткой времени, ID диалога и причиной.
NFR-04	`[ГИПОТЕЗА]`	Архитектура позволяет подключить CRM в v2 без переписывания ядра.

> **Явная граница MVP:** AI работает только с базой знаний. Персональные данные клиента из CRM недоступны (реализация в v2).

3. Целевая логика работы

3.1 ТЕКСТОВОЕ ОПИСАНИЕ

1. Клиент отправляет сообщение.
2. Система ожидает паузу DEBOUNCE_TIMEOUT — если клиент продолжает набирать, ждёт окончания.
3. Классификация обращения:
   - **Чувствительная тема** → немедленно оператору с пометкой; AI не отвечает.
   - **Обычный вопрос** → AI начинает генерацию.
4. Если генерация > TYPING_INDICATOR_TIMEOUT → клиенту отправляется заглушка.
5. Если генерация > MAX_GENERATION_TIMEOUT → оператору; AI останавливается.
6. Оценка уверенности:
   - **≥ порога** → ответ клиенту; оператор видит ответ + источник.
   - **< порога** → оператору с черновиком.
7. Если **оператор взял диалог** — немедленное взаимоисключение: незавершенная генерация отменяется, AI блокируется.
8. Клиент может в любой момент нажать "Позвать оператора" → AI останавливается.
9. При эскалации без операторов в линии → автоответ клиенту, диалог в очередь.

3.2 КОМПАКТНАЯ СХЕМА СОСТОЯНИЙ (MERMAID)

Подробная визуальная схема потока приведена в **Приложении Б**.

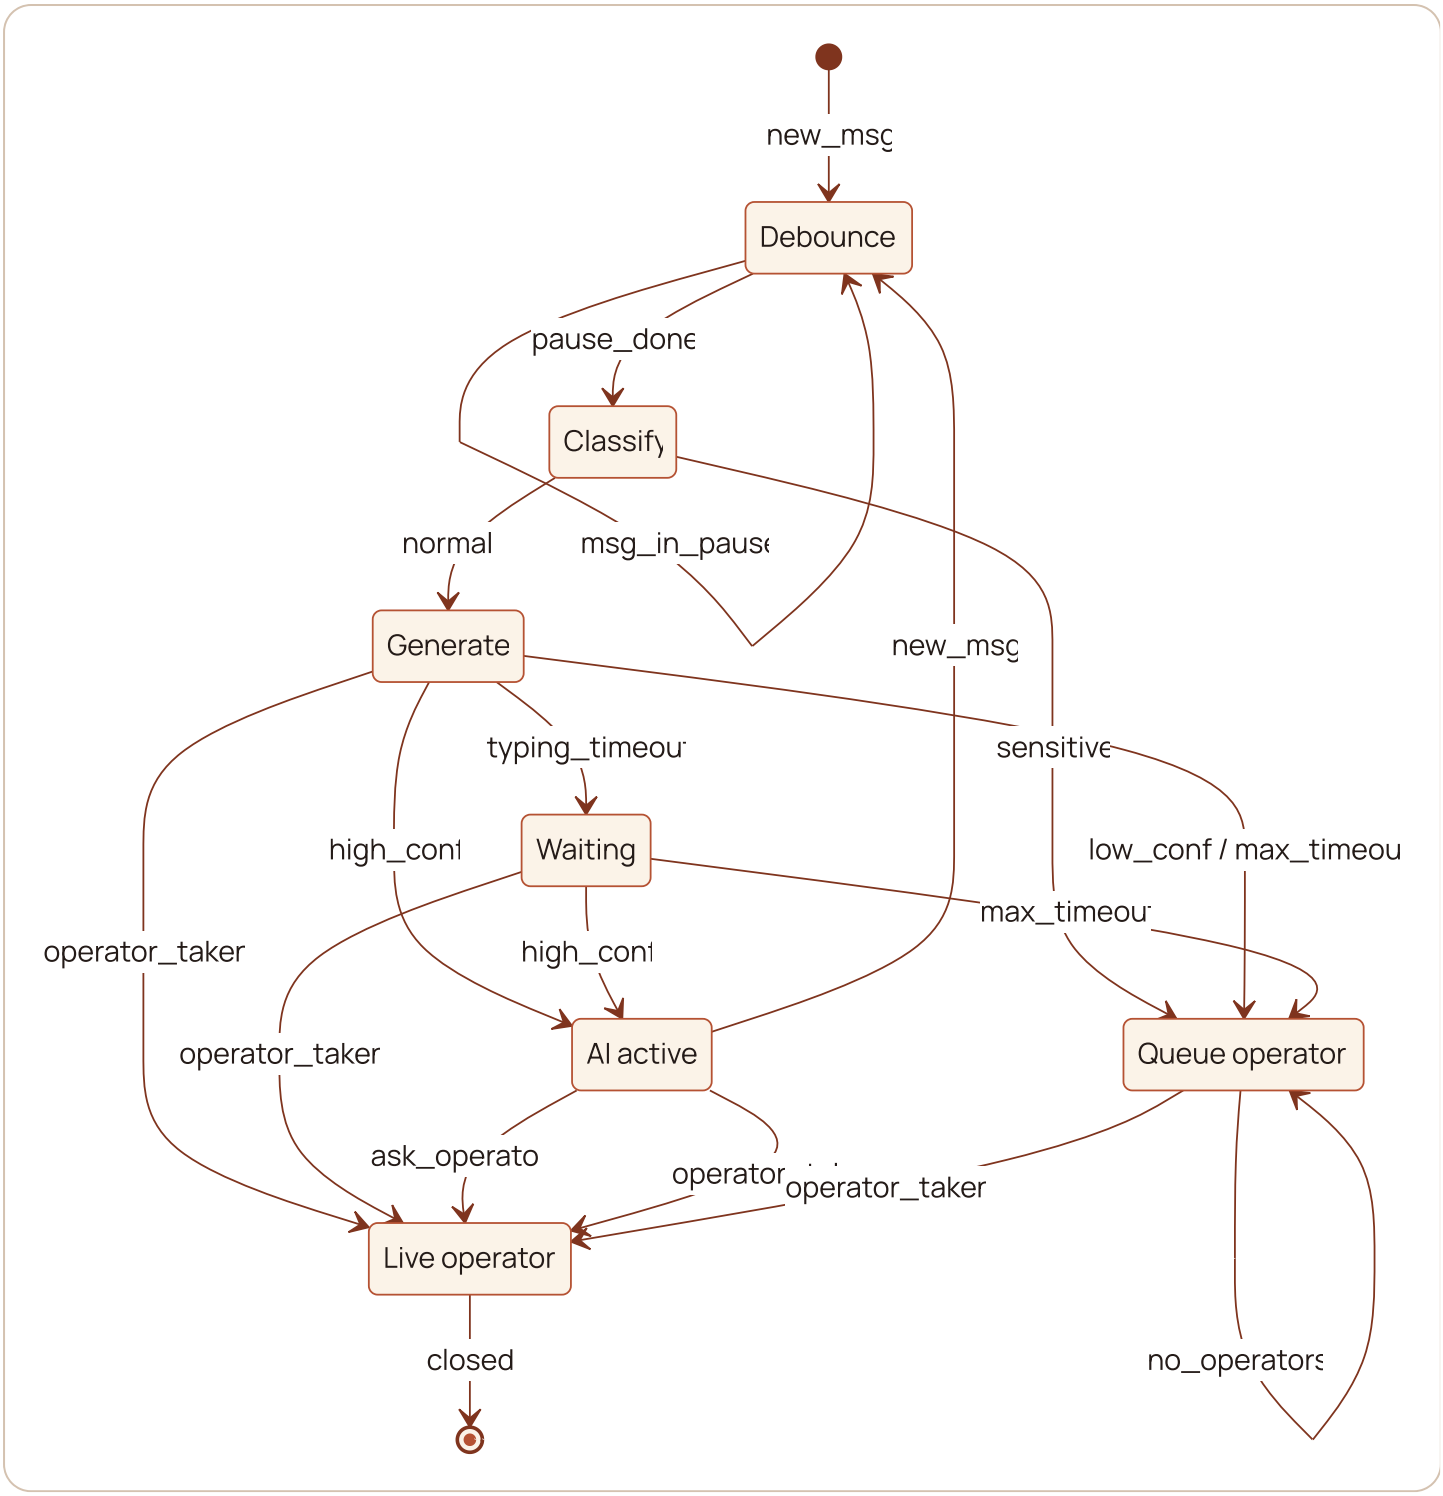

3.3 ТАБЛИЦА СОСТОЯНИЙ И ДОПУСТИМЫХ ПЕРЕХОДОВ

Состояние	Переход в	Условие
`[*] / AI_ACTIVE`	`DEBOUNCING`	получено сообщение клиента
`DEBOUNCING`	`DEBOUNCING`	новое сообщение в пределах DEBOUNCE_TIMEOUT
`DEBOUNCING`	`CLASSIFYING`	пауза ≥ DEBOUNCE_TIMEOUT
`CLASSIFYING`	`OPERATOR_PENDING`	тема = чувствительная
`CLASSIFYING`	`AI_GENERATING`	тема = обычная / нераспознанная
`AI_GENERATING`	`AI_WAITING`	генерация > TYPING_INDICATOR_TIMEOUT

Состояние	Переход в	Условие
`AI_GENERATING`	`OPERATOR_PENDING`	генерация > MAX_GENERATION_TIMEOUT ИЛИ уверенность < порога
`AI_GENERATING`	`AI_ACTIVE`	уверенность ≥ порога, ответ отправлен
`AI_GENERATING`	`OPERATOR_ACTIVE`	оператор взял диалог (взаимоисключение → генерация отменена)
`AI_WAITING`	`OPERATOR_PENDING`	генерация > MAX_GENERATION_TIMEOUT
`AI_WAITING`	`AI_ACTIVE`	уверенность ≥ порога, ответ отправлен
`AI_WAITING`	`OPERATOR_ACTIVE`	оператор взял диалог (взаимоисключение → генерация отменена)
`AI_ACTIVE`	`DEBOUNCING`	новое сообщение клиента
`AI_ACTIVE`	`OPERATOR_ACTIVE`	клиент нажал "Позвать оператора" ИЛИ оператор взял диалог
`OPERATOR_PENDING`	`OPERATOR_ACTIVE`	оператор взял диалог
`OPERATOR_PENDING`	`OPERATOR_PENDING`	нет операторов → автоответ клиенту
`OPERATOR_ACTIVE`	`[*]`	оператор закрыл диалог

3.4 ЧТО AI ОБРАБАТЫВАЕТ / НЕ ОБРАБАТЫВАЕТ

Тип обращения	AI отвечает?	Комментарий
FAQ, типовые вопросы по продукту	Да	При уверенности ≥ порога
Вопросы по статусу заказа / аккаунту	Нет (v2)	Требует CRM; в MVP недоступно
Медицинские, юридические темы	Нет	Всегда к оператору
Жалобы и претензии	Нет	Высокий риск, к оператору
Запрос на возврат средств	Нет	Требует авторизации действий
Нецензурная лексика / агрессия	Нет	Отдельный сценарий
Технические вопросы без ответа в базе	Нет	Низкая уверенность → к оператору

4. Вопросы к Product Manager / стейкхолдерам

ОБЯЗАТЕЛЬНО ДО СТАРТА РАЗРАБОТКИ

#	Тема	Вопрос	Рабочая гипотеза
Q1	Порог уверенности	Какое минимальное значение достаточно? Кто устанавливает и пересматривает?	`[ГИПОТЕЗА]` 0.75; пересмотр по результатам пилота
Q2	Чувствительные темы	Кто ведёт список? Как добавляется новая тема?	—
Q3	Таймауты	Значения TYPING_INDICATOR_TIMEOUT и MAX_GENERATION_TIMEOUT?	`[ГИПОТЕЗА]` 5 сек и 15 сек
Q4	Дебаунс	Через сколько секунд считать паузу? Максимум сообщений в очереди?	`[ГИПОТЕЗА]` 2–3 сек

#	Тема	Вопрос	Рабочая гипотеза
Q5	"Взял диалог"	Оператор открыл вкладку / нажал "Принять" / отправил первое сообщение?	—
Q6	Механизм недовольства	Кнопка оценки? Триггерная фраза? Повторный вопрос?	[ГИПОТЕЗА] Считать "недовольством" негативный сентимент в следующем сообщении ИЛИ нажатие👎 — прошу подтвердить
Q7	Нерабочее время	Что получает клиент при эскалации ночью / в выходные? Автоответ? Только AI без эскалации?	[ГИПОТЕЗА] Автоответ "ответим в рабочее время" + диалог в очередь
Q8	Оператор и интерфейс	Нужна ли подсказка "Последний ответ дал AI"? Как оператор продолжает без повторения сказанного ботом?	—
Q9	SLA оператора	Есть ли максимальное время ответа после получения диалога? Что при превышении?	—
Q10	Аналитика	Какие метрики с первого дня?	% передач, P95 времени, точность

ЮРИДИЧЕСКИЕ ТРЕБОВАНИЯ И ПРИВАТНОСТЬ (PM + КОМПЛАЕНС)

#	Вопрос
Q11	Срок хранения логов AI-диалогов, кто имеет доступ?
Q12	Маскирование ПДн в логах (ФИО, телефон, email в текстах сообщений)?
Q13	Кто имеет доступ к "обоснованию" ответа AI (источник, скор уверенности)?
Q14	Необходимо ли согласование формулировок заглушек и автоответов с юридическим отделом?

5. Задача для разработки: MVP

НАЗВАНИЕ

[FEAT] AI-оператор: автоматические ответы в чате с управляемой передачей оператору — MVP

ПРОБЛЕМА / ЦЕЛЬ

Операторы перегружены типовыми обращениями. Клиенты ждут дольше допустимого. Необходим автоматический агент, снимающий нагрузку без ошибок на чувствительных темах и без дублирования работы живых операторов.

ОБЪЕМ MVP

Компонент	Приоритет
Классификатор тем (чувствительная / нечувствительная)	[MUST MVP]
Генерация ответа по базе знаний	[MUST MVP]
Оценка уверенности и логика порога	[MUST MVP]

Компонент	Приоритет
Дебаунсинг входящих сообщений	`[MUST MVP]`
Заглушка при долгой генерации	`[MUST MVP]`
Автопередача оператору при таймауте и низкой уверенности	`[MUST MVP]`
Взаимоисключение: блокировка AI при подключении оператора (FR-13)	`[MUST MVP]`
Кнопка "Позвать оператора" для клиента	`[MUST MVP]`
Отображение ответа AI + источника в интерфейсе оператора	`[MUST MVP]`
Автоответ при эскалации в нерабочее время	`[MUST MVP]`
Базовое логирование действий AI	`[MUST MVP]`
Настройка порогов через интерфейс	`[ГИПОТЕЗА]` → v1.1

Не входит в объем (MVP): интеграция с CRM, мультиканальность, автозакрытие диалога, дообучение модели, A/B-тестирование порогов, аналитический дашборд.

МЕТРИКИ УСПЕХА MVP

Метрика	Описание	Целевое значение
Доля автоматически закрытых диалогов	% диалогов без участия оператора	Базовый прогноз после 2 нед. пилота
Доля эскалаций	% диалогов, переданных оператору (любая причина)	Базовый прогноз после пилота
P95 времени ответа AI	95-й перцентиль времени от сообщения до ответа	≤ 10 сек
Доля ошибочных ответов по чувствительным темам	AI ответил там, где должен был передать оператору	0%
Среднее время первого ответа оператора после эскалации	После передачи диалога	Определяется по базовым данным

> Цели по снижению нагрузки и росту автоматизации — **гипотеза**, требует базового прогноза по историческим данным. Фиксируются как ориентиры по итогам пилота.

КЛЮЧЕВЫЕ ПАРАМЕТРЫ

Параметр	Описание	Значение по умолчанию
`DEBOUNCE_TIMEOUT`	Пауза перед обработкой	2–3 сек `[ГИПОТЕЗА]`
`CONFIDENCE_THRESHOLD`	Минимальная уверенность AI	0.75 `[ГИПОТЕЗА]`
`TYPING_INDICATOR_TIMEOUT`	Таймаут до заглушки	5 сек `[ГИПОТЕЗА]`
`MAX_GENERATION_TIMEOUT`	Максимум генерации	15 сек `[ГИПОТЕЗА]`

КРИТЕРИИ ПРИЁМКИ

AC-ID	Условие	Ожидаемый результат
AC-01	Клиент отправил сообщение по чувствительной теме	AI не отвечает; диалог передаётся оператору с пометкой темы
AC-02	AI сформировал ответ с уверенностью < CONFIDENCE_THRESHOLD	Ответ не отправляется; диалог уходит оператору с черновиком и причиной

AC-ID	Условие	Ожидаемый результат
AC-03	Клиент отправил 3 сообщения с паузами < DEBOUNCE_TIMEOUT	Система ждёт; AI отвечает один раз на агрегированный контекст
AC-04	Генерация занимает > TYPING_INDICATOR_TIMEOUT	Клиент получает сообщение-заглушку
AC-05	Генерация занимает > MAX_GENERATION_TIMEOUT	Диалог автоматически передаётся оператору; AI останавливается
AC-06	Оператор нажал "Принять" или отправил первое сообщение	AI немедленно прекращает генерацию (взаимоисключение); новые ответы AI в этом диалоге не отправляются
AC-07	Клиент нажал "Позвать оператора"	AI останавливается; диалог передаётся оператору
AC-08	AI отправил ответ клиенту	Оператор видит ответ AI + источник из базы знаний в своём интерфейсе
AC-09	Любое действие AI (генерация, передача, таймаут)	Событие записывается в лог с меткой времени и ID диалога
AC-10	Система обрабатывает стандартный трафик	P95 времени от сообщения клиента до ответа AI ≤ 10 сек
AC-11*(негативный)*	Клиент отправил новое сообщение**во время генерации** ответа AI	Текущая генерация отменяется; запускается новый дебаунс с полным контекстом
AC-12*(негативный)*	Оператор открыл чат**после** ответа AI и написал продолжение	AI не генерирует; оператор видит историю с ответом AI и продолжает диалог без повторения
AC-13*(негативный)*	Инициирована эскалация, операторов нет в линии	Клиент получает автоответ с временем следующего ответа; диалог сохраняется в очереди

ТРАССИРОВКА FR → AC

FR-ID	AC-ID	Краткое описание
FR-01, FR-02, FR-05	AC-01	Чувствительная тема → немедленно оператору
FR-03, FR-04	AC-02	Низкая уверенность → оператору с черновиком
FR-07	AC-03, AC-11	Дебаунсинг: агрегация сообщений и отмена генерации
FR-08	AC-04	Заглушка при долгой генерации
FR-09	AC-05	MAX_TIMEOUT → автоэскалация
FR-06, FR-13	AC-06, AC-12	Взаимоисключение: оператор взял → AI заблокирован
FR-10	AC-07	Кнопка "Позвать оператора"
FR-11, FR-12	AC-08, AC-12	Оператор видит историю AI
NFR-03	AC-09	Логирование всех действий AI
NFR-01	AC-10	P95 ≤ 10 сек
FR-14	AC-13	Нерабочее время — автоответ + очередь

ЗАВИСИМОСТИ И РИСКИ

#	Тема	Описание	Ответственный
Q1	Список чувствительных тем	Без него невозможен классификатор	PM
Q2	Значения таймаутов	Не согласованы; влияют на пользовательский опыт	PM + техлид
Q3	"Взял диалог"	Не определено событие-триггер взаимоисключение	PM + фронтенд
Q4	Механизм недовольства	Рабочая гипотеза: негативный сентимент ИЛИ 👎	PM
D1	База знаний	Качество ответов AI прямо зависит от полноты базы	Content-команда
D2	ML confidence score	FR-03 предполагает калиброванный скор от модели. Если скор недоступен — запасной вариант: только RAG + порог релевантности чанков	ML-команда
R1	Галлюцинации AI	При низком пороге AI отвечает неточно	A/B после MVP
R2	Перегрузка операторов	При высоком пороге все диалоги уйдут к людям	Мониторинг с первого дня
R3	Состояние гонки	Закрыт FR-13 (взаимоисключение); требует ревью техлида	техлид

ИЗМЕНЕНИЯ В РАБОЧЕМ ПРОЦЕССЕ ОПЕРАТОРА (УПРАВЛЕНИЕ ИЗМЕНЕНИЯМИ)

При внедрении AI-оператора рабочий процесс операторов изменится. До старта разработки необходимо уточнить с PM:

- Нужно ли обучение операторов новому интерфейсу?
- Как оператор понимает, что диалог уже обработан AI (явная метка в интерфейсе)?
- Нужна ли подсказка: *"Последний ответ клиенту дал AI"*?
- Как оператор продолжает диалог без повторения сказанного ботом?

Приложение A: Предложение по этапам развития

> Цифры по снижению нагрузки — **гипотезы**, подлежат подтверждению на пилоте по историческим данным.

Этап	Содержание	Ожидаемый эффект
MVP	Классификатор тем, генерация по базе знаний, порог уверенности, передача оператору, взаимоисключение	Базовая автоматизация; замер реального снижения нагрузки
v1.1	Кнопка оценки ответа AI клиентом, базовый аналитический дашборд, настройка порогов через интерфейс	Измерение качества; инструмент обратной связи для операторов
v2.0	Интеграция с CRM, персонализированные ответы, A/B-тесты порогов	Рост автоматизации; сокращение времени ответа
v3.0	Дообучение модели на исторических диалогах, мультиканальность	Умный оператор с памятью контекста клиента

Приложение Б: Визуальная схема потока

Б.1 ОБРАБОТКА СООБЩЕНИЯ AI

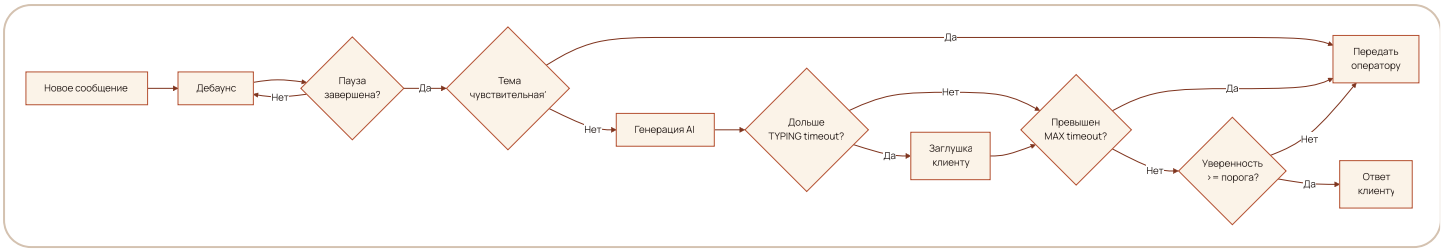
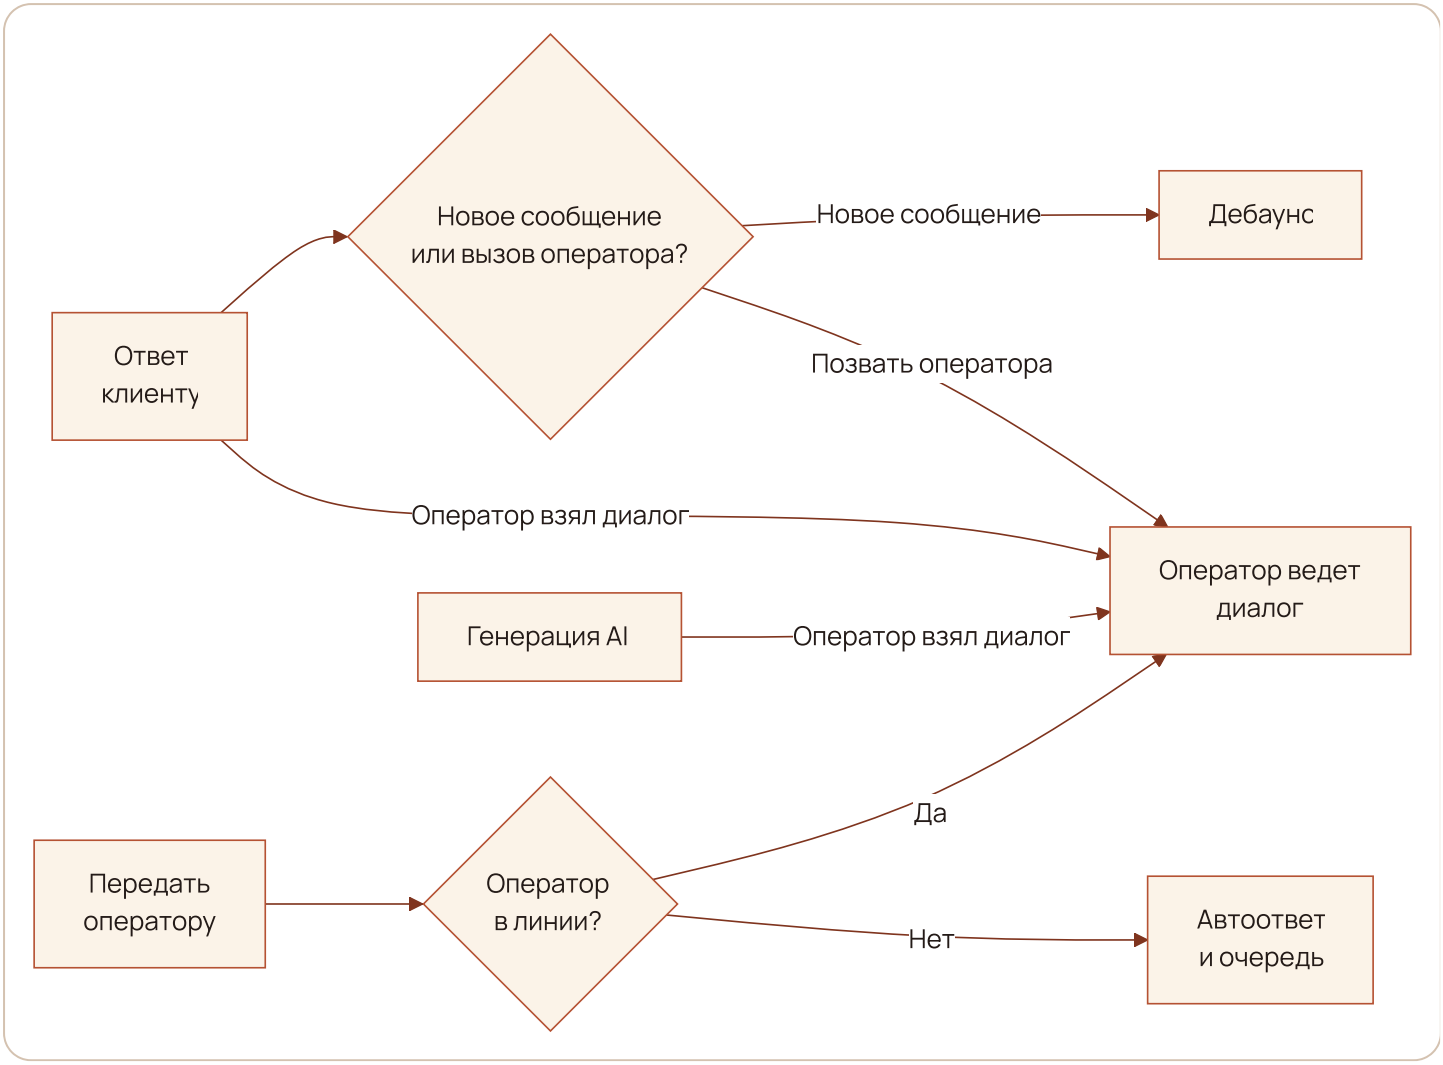
Б.2 ЭСКАЛАЦИЯ И ПРОДОЛЖЕНИЕ ДИАЛОГА